Práctica 1. Importación de datos

Análisis Exploratorio de Datos. Máster en Ciencia de Datos - UV

Carlos Galdámez Huertas (galhuer)

2026-10-20

Índice

1. Introducción **1**

2. DFP1_11122015 124700.csv **1**

3. Transactions from a Bakery **3**

4. PsychBike.sav **4**

5. iris.zip **5**

6. iris.data **5**

7. FileCodificado.json **5**

8. iris_json.json **6**

8.1. Exportación a JSON 6

1. Introducción

Se importaron los ficheros en data frames y se guardaron en `results`. Se usaron `str` para ver los tipos, `head` y `tail` para revisar los extremos, y `summary` para resumir las variables. Las rutas son relativas al proyecto.

2. DFP1_11122015 124700.csv

El separador es un tabulador. Se compararon las lecturas de base y readr, y se convirtieron la fecha y la hora. Ambas lecturas contienen los mismos datos.

```
fname <- 'data/DFP1_11122015 124700.csv'
Deposito <- read.csv(fname, sep = '\t', stringsAsFactors = FALSE)
Deposito_readr <- read_delim(fname, delim = '\t', col_types = 'ccddd')
all.equal(Deposito, as.data.frame(Deposito_readr),
          check.attributes = FALSE)
```

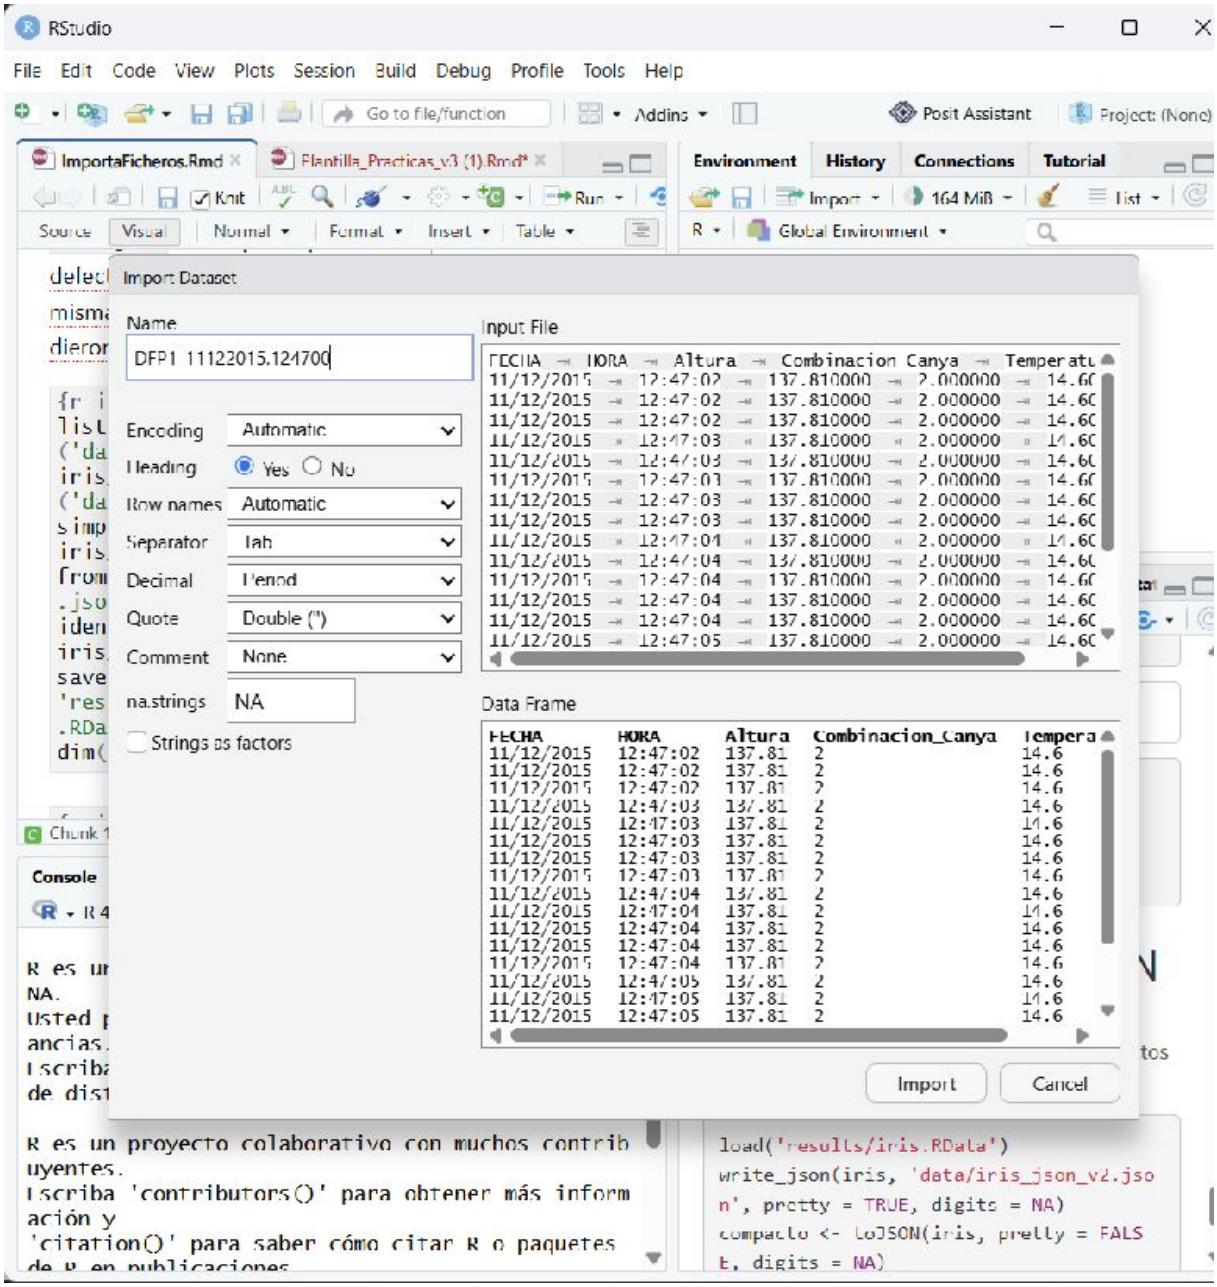
```
[1] TRUE
```

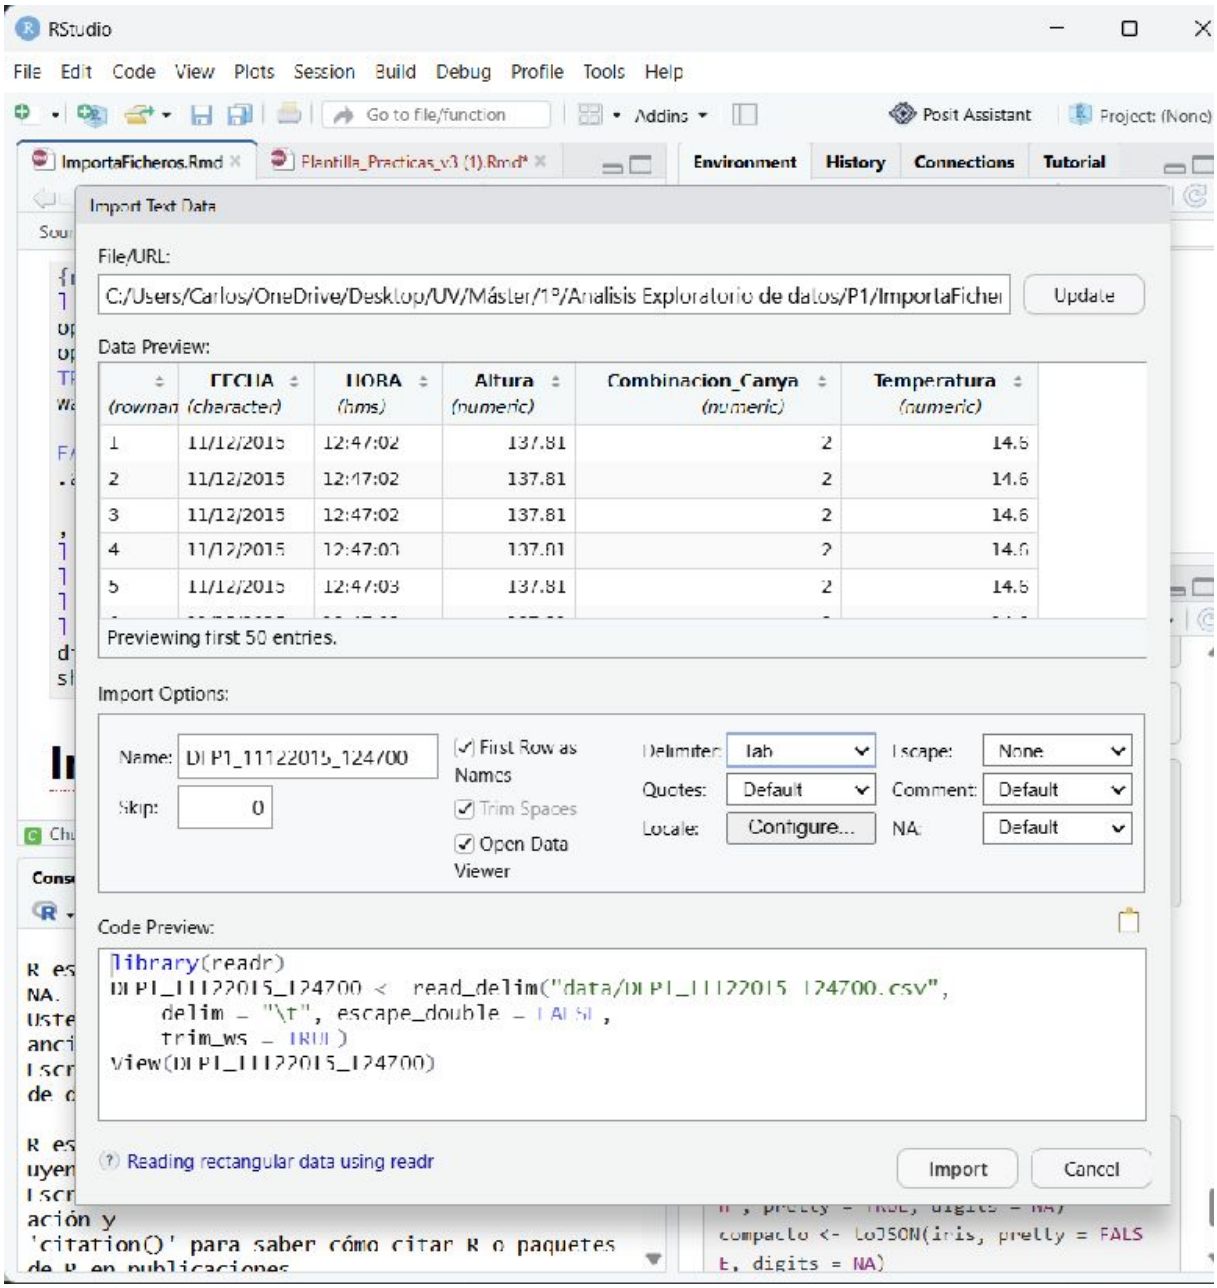
```
Deposito$FECHA <- as.POSIXlt(Deposito$FECHA,
                             format = '%d/%m/%Y', tz = 'UTC')
Deposito$HORA <- as_hms(Deposito$HORA)
save(Deposito, file = 'results/Deposito.RData')
dim(Deposito)
```

```
[1] 8887    5
```

```
str(Deposito)
head(Deposito)
tail(Deposito)
Deposito_resumen <- Deposito
Deposito_resumen$HORA <- as.numeric(Deposito_resumen$HORA)
summary(Deposito_resumen)
```

Las horas se resumieron en segundos para evitar un fallo de formato de `summary` con la clase `hms`. El objeto guardado conserva la clase horaria.





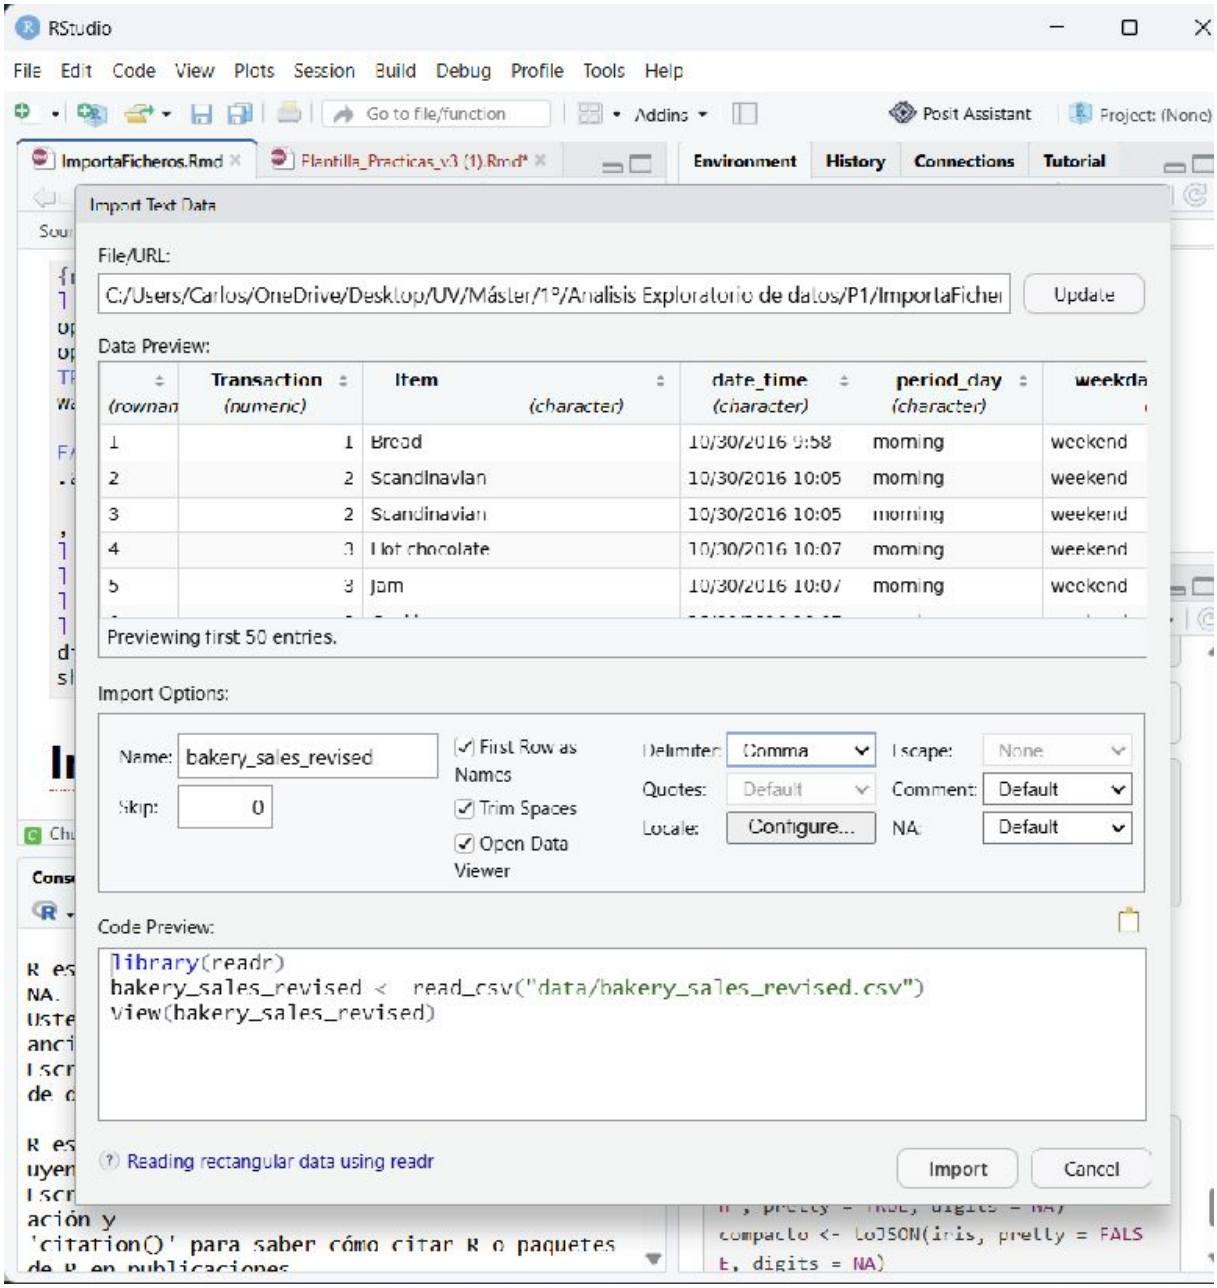
3. Transactions from a Bakery

Se descargó el fichero de Kaggle y se previsualizó con readr en RStudio. La fecha se detectó como texto; se añadió su formato al código generado. Cada fila es un artículo de una compra.

```
BreadBasket <- as.data.frame(read_csv('data/bakery_sales_revised.csv',
  col_types = cols(Transaction = col_integer(), Item = col_character(),
    date_time = col_datetime('%m/%d/%Y %H:%M'),
    period_day = col_character(), weekday_weekend = col_character())))
save(BreadBasket, file = 'results/BreadBasket.RData')
dim(BreadBasket)
```

```
[1] 20507     5
```

```
str(BreadBasket)
head(BreadBasket)
tail(BreadBasket)
summary(BreadBasket)
```



4. PsychBike.sav

Se leyó con `read_sav`. Se conservaron los códigos y las etiquetas de SPSS.

```
PsychBike <- as.data.frame(read_sav('data/PsychBike.sav'))
save(PsychBike, file = 'results/PsychBike.RData')
dim(PsychBike)
```

```
[1] 2355    6
```

```
str(PsychBike)
head(PsychBike)
tail(PsychBike)
PsychBike_resumen <- PsychBike
PsychBike_resumen$hour <- as.numeric(PsychBike_resumen$hour)
summary(PsychBike_resumen)
```

5. iris.zip

Se descargó el ZIP de Iris en UCI y se descomprimió con `unzip`.

```
unzip('data/iris.zip', exdir = 'data')
```

6. iris.data

El fichero tiene comas y no tiene cabecera. Se sustituyeron las comas por espacios en memoria para leerlo con `read_table`. Las cuatro medidas están en cm.

```
lineas <- readLines('data/iris.data', warn = FALSE)
texto <- paste(gsub(',', ' ', lineas, fixed = TRUE), collapse = '\n')
iris <- as.data.frame(read_table(I(texto), col_types = 'ddddc',
  col_names = c('Sepal.Length', 'Sepal.Width', 'Petal.Length',
                'Petal.Width', 'Species')))
save(iris, file = 'results/iris.RData')
dim(iris)
```

```
[1] 150   5
```

```
str(iris)
head(iris)
tail(iris)
summary(iris)
```

7. FileCodificado.json

Se leyó con y sin simplificación. Sin `simplifyVector` se obtiene una lista; con `TRUE`, un data frame de 83 filas y 22 columnas.

```
lista <- read_json('data/FileCodificado.json')
FileCodificado <- read_json('data/FileCodificado.json',
                            simplifyVector = TRUE)
class(lista)
```

```
[1] "list"
```

```
class(FileCodificado)
```

```
[1] "data.frame"
```

```r
save(FileCodificado, file = 'results/FileCodificado.RData')
dim(FileCodificado)
```

```
[1] 83 22
```

```r
str(FileCodificado)
head(FileCodificado)
tail(FileCodificado)
summary(FileCodificado)
```

8. iris_json.json

`read_json` no simplifica por defecto y `fromJSON` sí. Con la misma opción de simplificación dieron el mismo data frame.

```r
lista_iris <- read_json('data/iris_json.json')
iris_json <- read_json('data/iris_json.json', simplifyVector = TRUE)
iris_fromJSON <- fromJSON('data/iris_json.json')
identical(iris_json, iris_fromJSON)
```

```
[1] TRUE
```

```r
save(iris_json, file = 'results/iris_json.RData')
dim(iris_json)
```

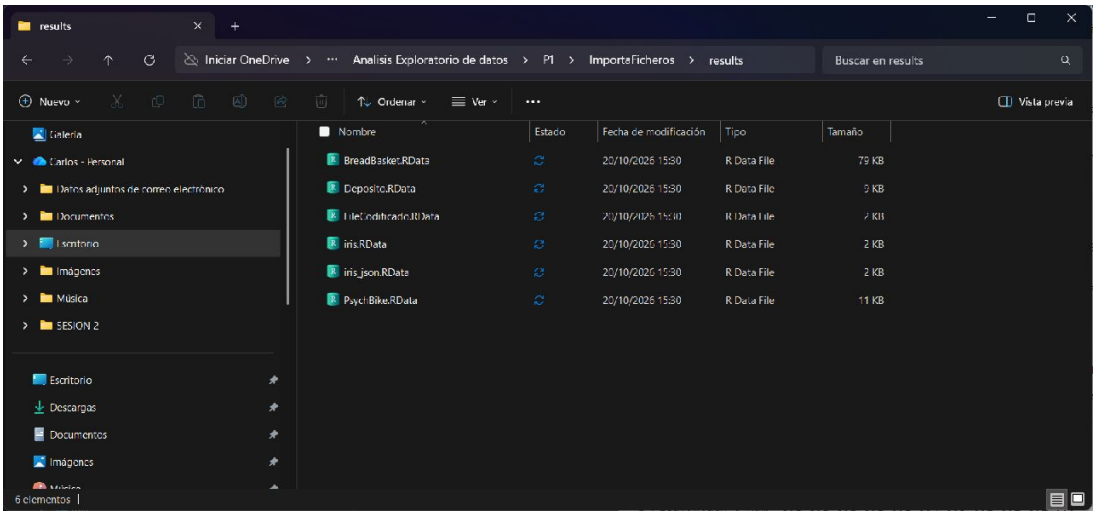
```
[1] 150   5
```

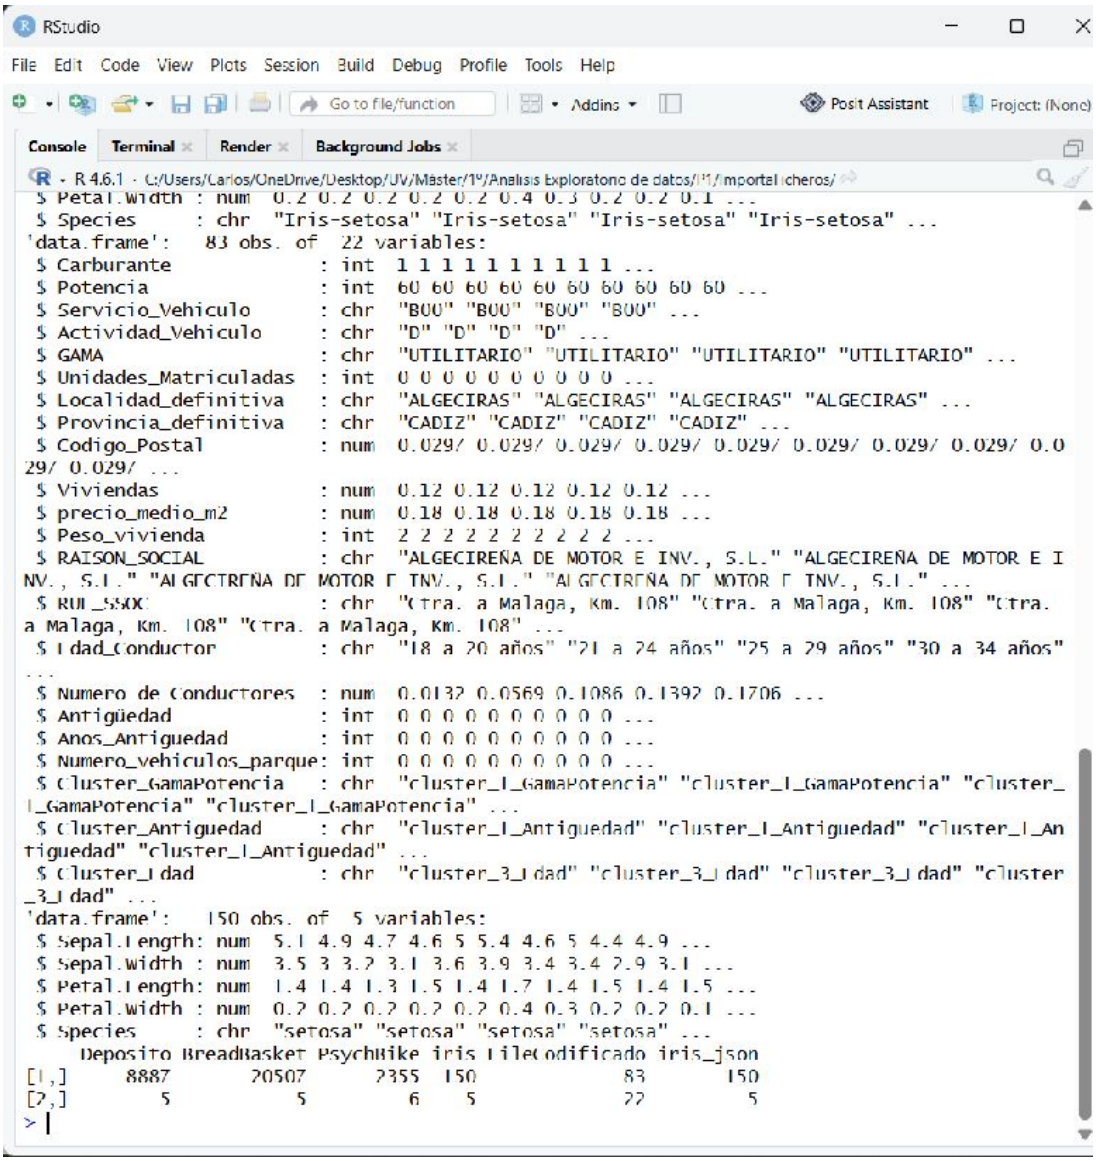
```r
str(iris_json)
head(iris_json)
tail(iris_json)
summary(iris_json)
```

8.1. Exportación a JSON

Se cargó `iris.RData` y se exportó con ambas funciones. `pretty = TRUE` añadió sangría y saltos de línea; no cambió los datos.

```r
load('results/iris.RData')
write_json(iris, 'data/iris_json_v2.json', pretty = TRUE, digits = NA)
compacto <- toJSON(iris, pretty = FALSE, digits = NA)
legible <- toJSON(iris, pretty = TRUE, digits = NA)
write_file(compacto, 'data/iris_compacto.json')
write_file(legible, 'data/iris_pretty.json')
```


results
Iniciar OneDrive
Analisis Exploratorio de datos
P1
ImportaFicheros
results
Buscar en results
Nuevo
Ordenar
Ver
Vista previa
Galería
Carlos - Personal
Datos adjuntos de correo electrónico
Documentos
Escritorio
Imágenes
Música
SESION 2
Escritorio
Descargas
Documentos
Imágenes
Nombre
Estado
Fecha de modificación
Tipo
Tamaño
BreadBasket.RData
20/10/2026 15:30
R Data File
79 KB
Deposito.RData
20/10/2026 15:30
R Data File
9 KB
iris.RData
20/10/2026 15:30
R Data File
2 KB
iris_json.RData
20/10/2026 15:30
R Data File
2 KB
PsychBike.RData
20/10/2026 15:30
R Data File
11 KB
6 elementos


RStudio
File Edit Code View Plots Session Build Debug Profile Tools Help
Go to file/function
Addins
Posit Assistant
Project: (None)
Console
Terminal
Render
Background Jobs
R 4.6.1 · C:/Users/Carlos/OneDrive/Desktop/UV/Master/1º/Analisis Exploratorio de datos/P1/ImportaFicheros/
$ Petal.Width : num 0.2 0.2 0.2 0.2 0.2 0.4 0.3 0.2 0.2 0.1 ...
$ Species : chr "Iris-setosa" "Iris-setosa" "Iris-setosa" "Iris-setosa" ...
'data.frame': 83 obs. of 22 variables:
$ Carburante : int 1 1 1 1 1 1 1 1 1 1 ...
$ Potencia : int 60 60 60 60 60 60 60 60 60 60 ...
$ Servicio_Vehiculo : chr "BUO" "BUO" "BUO" "BUO" ...
$ Actividad_Vehiculo : chr "D" "D" "D" "D" ...
$ GAMA : chr "UTILITARIO" "UTILITARIO" "UTILITARIO" "UTILITARIO" ...
$ Unidades_Matriculadas : int 0 0 0 0 0 0 0 0 0 0 ...
$ Localidad_definitiva : chr "ALGECIRAS" "ALGECIRAS" "ALGECIRAS" "ALGECIRAS" ...
$ Provincia_definitiva : chr "CADIZ" "CADIZ" "CADIZ" "CADIZ" ...
$ Codigo_Postal : num 0.029/ 0.029/ 0.029/ 0.029/ 0.029/ 0.029/ 0.029/ 0.029/ 0.029/ 0.029/ ...
$ Viviendas : num 0.12 0.12 0.12 0.12 0.12 ...
$ precio_medio_m2 : num 0.18 0.18 0.18 0.18 0.18 ...
$ Peso_vivienda : int 2 2 2 2 2 2 2 2 2 2 ...
$ RAISON_SOCIAL : chr "ALGECIREÑA DE MOTOR E INV., S.L." "ALGECIREÑA DE MOTOR E INV., S.L." "ALGECIREÑA DE MOTOR E INV., S.L." ...
$ RUE_SOC : chr "Ctra. a Malaga, Km. 108" "Ctra. a Malaga, Km. 108" "Ctra. a Malaga, Km. 108" ...
$ Edad_Conductor : chr "18 a 20 años" "21 a 24 años" "25 a 29 años" "30 a 34 años" ...
$ Numero de Conductores : num 0.0132 0.0569 0.1086 0.1392 0.1706 ...
$ Antigüedad : int 0 0 0 0 0 0 0 0 0 0 ...
$ Anos_Antiguedad : int 0 0 0 0 0 0 0 0 0 0 ...
$ Numero_vehiculos_parque: int 0 0 0 0 0 0 0 0 0 0 ...
$ Cluster_GamaPotencia : chr "cluster_1_GamaPotencia" "cluster_1_GamaPotencia" "cluster_1_GamaPotencia" "cluster_1_GamaPotencia" ...
$ Cluster_Antiguedad : chr "cluster_1_Antiguedad" "cluster_1_Antiguedad" "cluster_1_Antiguedad" "cluster_1_Antiguedad" ...
$ Cluster_Edad : chr "cluster_3_Edad" "cluster_3_Edad" "cluster_3_Edad" "cluster_3_Edad" ...
'data.frame': 150 obs. of 5 variables:
$ Sepal.Length: num 5.1 4.9 4.7 4.6 5 5.4 4.6 5 4.4 4.9 ...
$ Sepal.Width : num 3.5 3 3.2 3.1 3.6 3.9 3.4 3.4 2.9 3.1 ...
$ Petal.Length: num 1.4 1.4 1.3 1.5 1.4 1.7 1.4 1.5 1.4 1.5 ...
$ Petal.Width : num 0.2 0.2 0.2 0.2 0.2 0.4 0.3 0.2 0.2 0.1 ...
$ Species : chr "setosa" "setosa" "setosa" "setosa" ...
Deposito BreadBasket PsychBike iris FileCodificado iris_json
[1,] 8887 20507 2355 150 83 150
[2,] 5 5 6 5 22 5
>