Práctica 3 y 4. Preparación y manejo de Datos

Análisis Exploratorio de Datos. Máster en Ciencia de Datos - UV

Carlos Galdámez Huertas (galhuer)

2026-10-29

Índice

1. Ejercicio 1 **2**

2. Ejercicio 2 **3**

3. Ejercicio 3 **3**

4. Ejercicio 4 **4**

5. Ejercicio 5 **5**

6. Ejercicio 6 **6**

7. Ejercicio 7 **6**

8. Ejercicio 8 **7**

9. Ejercicio 9 **7**

10.Ejercicio 10 **7**

11.Ejercicio 11 **7**

12.Ejercicio extra 1 **8**

13.Ejercicio extra 2 **9**

14.Ejercicio extra 3 **9**

15.Ejercicio extra 4 **10**

16.Ejercicio extra 5 **11**

1. Ejercicio 1

Se agruparon los intervalos de ingresos en una columna de tipo factor y los casos en otra.

```
load('data/pew_religion.Rdata')
pew_tidy <- gather(pew_religion, income, freq, -religion, factor_key = TRUE)
head(pew_tidy)
```

```
            religion income freq
1           Agnostic  <$10k   27
2            Atheist  <$10k   12
3           Buddhist  <$10k   27
4           Catholic  <$10k  418
5 Don't know/refused  <$10k   15
6   Evangelical Prot  <$10k  575
```

2. Ejercicio 2

Se agruparon las semanas y las posiciones en dos columnas.

```
load('data/billboard.Rdata')
billboard_tidy <- pivot_longer(raw, wk1:wk76, names_to = 'week',
                               values_to = 'rank', names_prefix = 'wk')
head(billboard_tidy[, c('artist', 'week', 'rank')])
```

```
# A tibble: 6 x 3
  artist week   rank
  <chr>  <chr> <int>
1 2 Pac  1        87
2 2 Pac  2        82
3 2 Pac  3        72
4 2 Pac  4        77
5 2 Pac  5        87
6 2 Pac  6        94
```

3. Ejercicio 3

Se agruparon los casos y se separaron el sexo y la edad.

```
load('data/tb.Rdata')
tb_tidy <- raw %>%
  gather(grupo, casos, -country, -year) %>%
  separate(grupo, into = c('sexo', 'edad'), sep = 1)
head(tb_tidy)
```

```
  country year sexo edad casos
1      AD 2000    m  014     0
2      AE 2000    m  014     2
3      AF 2000    m  014    52
4      AG 2000    m  014     0
5      AL 2000    m  014     2
6      AM 2000    m  014     2
```

4. Ejercicio 4

Se agruparon los días, se creó la fecha y se separaron las temperaturas.

```
load('data/weather.Rdata')
weather_tidy <- raw %>%
  pivot_longer(d1:d31, names_to = 'dia', names_prefix = 'd',
               values_to = 'temperatura', values_drop_na = TRUE) %>%
  mutate(fecha = make_date(year, month, as.integer(dia))) %>%
  select(-year, -month, -dia) %>%
  pivot_wider(names_from = element, values_from = temperatura)
head(weather_tidy)
```

```
# A tibble: 6 x 4
  id      fecha       tmax  tmin
  <chr>   <date>     <dbl> <dbl>
1 MX17004 2010-01-30  27.8  14.5
2 MX17004 2010-02-02  27.3  14.4
3 MX17004 2010-02-03  24.1  14.4
4 MX17004 2010-02-11  29.7  13.4
5 MX17004 2010-02-23  29.9  10.7
6 MX17004 2010-03-05  32.1  14.2
```

5. Ejercicio 5

```
load('data/VuelosNY.Rdata')
head(flights)
```

```
  year month day dep_time sched_dep_time dep_delay arr_time sched_arr_time
1 2013     1   1      517            515         2      830            819
2 2013     1   1      533            529         4      850            830
3 2013     1   1      542            540         2      923            850
4 2013     1   1      544            545        -1     1004           1022
5 2013     1   1      554            600        -6      812            837
6 2013     1   1      554            558        -4      740            728
  arr_delay carrier flight tailnum origin dest air_time distance hour minute
1        11      UA   1545  N14228    EWR  IAH      227     1400    5     15
2        20      UA   1714  N24211    LGA  IAH      227     1416    5     29
3        33      AA   1141  N619AA    JFK  MIA      160     1089    5     40
4       -18      B6    725  N804JB    JFK  BQN      183     1576    5     45
5       -25      DL    461  N668DN    LGA  ATL      116      762    6      0
6        12      UA   1696  N39463    EWR  ORD      150      719    5     58
   time_hour
1 1357034400
2 1357034400
3 1357034400
4 1357034400
5 1357038000
6 1357034400
```

```
head(planes)
```

```
  tailnum year                type     manufacturer     model engines seats
1  N10156 2004 Fixed wing multi engine          EMBRAER EMB-145XR       2    55
2  N102UW 1998 Fixed wing multi engine AIRBUS INDUSTRIE  A320-214       2   182
3  N103US 1999 Fixed wing multi engine AIRBUS INDUSTRIE  A320-214       2   182
4  N104UW 1999 Fixed wing multi engine AIRBUS INDUSTRIE  A320-214       2   182
5  N10575 2002 Fixed wing multi engine          EMBRAER EMB-145LR       2    55
6  N105UW 1999 Fixed wing multi engine AIRBUS INDUSTRIE  A320-214       2   182
  speed    engine
1    NA Turbo-fan
2    NA Turbo-fan
3    NA Turbo-fan
4    NA Turbo-fan
5    NA Turbo-fan
6    NA Turbo-fan
```

`flights` contiene información de cada vuelo, como las fechas, los horarios, los retrasos y los aeropuertos. `planes` describe cada avión, incluyendo su fabricante, modelo y número de asientos.

6. Ejercicio 6

Se filtraron los aviones y se unificaron los nombres de Airbus.

```
planes.f <- planes %>%
  filter(!grepl('MCDONNELL DOUGLAS', manufacturer)) %>%
  filter(seats >= 90, seats <= 210) %>%
  mutate(manufacturer = if_else(grepl('AIRBUS', manufacturer),
                                'AIRBUS COMP', manufacturer))
head(planes.f)
```

```
  tailnum year                     type manufacturer    model engines seats
1  N102UW 1998 Fixed wing multi engine  AIRBUS COMP A320-214       2   182
2  N103US 1999 Fixed wing multi engine  AIRBUS COMP A320-214       2   182
3  N104UW 1999 Fixed wing multi engine  AIRBUS COMP A320-214       2   182
4  N105UW 1999 Fixed wing multi engine  AIRBUS COMP A320-214       2   182
5  N107US 1999 Fixed wing multi engine  AIRBUS COMP A320-214       2   182
6  N108UW 1999 Fixed wing multi engine  AIRBUS COMP A320-214       2   182
  speed    engine
1    NA Turbo-fan
2    NA Turbo-fan
3    NA Turbo-fan
4    NA Turbo-fan
5    NA Turbo-fan
6    NA Turbo-fan
```

7. Ejercicio 7

Se seleccionaron los vuelos de los aviones filtrados.

```
flights.f <- semi_join(flights, planes.f, by = 'tailnum')
head(flights.f[, c('tailnum', 'origin', 'dest')])
```

```
  tailnum origin dest
1  N14228    EWR  IAH
2  N24211    LGA  IAH
3  N619AA    JFK  MIA
4  N804JB    JFK  BQN
5  N668DN    LGA  ATL
6  N39463    EWR  ORD
```

8. Ejercicio 8

Se asignaron los datos filtrados a los nombres originales.

```
planes <- planes.f
flights <- flights.f
```

9. Ejercicio 9

Se eliminaron las variables indicadas de ambos conjuntos.

```
flights <- flights %>% select(-time_hour, -ends_with('time'))
planes <- planes %>% select(-speed, -type)
```

10. Ejercicio 10

Se creó la fecha como texto y se eliminaron las columnas originales.

```
flights <- flights %>%
  mutate(Full_Date = format(make_date(year, month, day), '%d-%m-%Y')) %>%
  select(-year, -month, -day)
```

11. Ejercicio 11

Se calcularon el número de vuelos y las distancias de cada avión.

```
Distances_plane <- flights %>%
  filter(!is.na(tailnum)) %>%
  group_by(tailnum) %>%
  summarise(Num_flights = n(), Mean_distance = mean(distance),
            Total_distance = sum(distance))
head(Distances_plane)
```

```
# A tibble: 6 x 4
  tailnum Num_flights Mean_distance Total_distance
  <chr>         <int>         <dbl>          <dbl>
1 N102UW           48          536.          25722
2 N103US           46          535.          24619
3 N104UW           47          535.          25157
4 N105UW           45          525.          23618
5 N107US           41          529.          21677
6 N108UW           60          534.          32070
```

12. Ejercicio extra 1

Se separaron las canciones y sus posiciones usando un identificador.

```
canciones <- billboard_tidy %>%
  select(artist, track, time) %>%
  unique() %>%
  mutate(id = row_number())

ranking <- billboard_tidy %>%
  left_join(canciones, by = c('artist', 'track', 'time')) %>%
  select(id, week, rank) %>%
  unique()

head(canciones)
```

```
# A tibble: 6 x 4
  artist       track                   time     id
  <chr>        <chr>                   <chr> <int>
1 2 Pac        Baby Don't Cry          4:22      1
2 2Ge+her      The Hardest Part Of ... 3:15      2
3 3 Doors Down Kryptonite              3:53      3
4 3 Doors Down Loser                   4:24      4
5 504 Boyz     Wobble Wobble           3:35      5
6 98?          Give Me Just One Nig... 3:24      6
```

```
head(ranking)
```

```
# A tibble: 6 x 3
     id week   rank
  <int> <chr> <int>
1     1 1        87
2     1 2        82
3     1 3        72
4     1 4        77
5     1 5        87
6     1 6        94
```

13. Ejercicio extra 2

Se unió el año, se separaron los casos y la población y se cambiaron sus tipos.

```
tabla <- table5 %>%
  unite(year, century, year, sep = '') %>%
  separate(rate, into = c('cases', 'population'), sep = '/') %>%
  mutate(across(c(year, cases, population), as.numeric))
tabla
```

```
# A tibble: 6 x 4
  country      year  cases population
  <chr>       <dbl>  <dbl>      <dbl>
1 Afghanistan  1999    745   19987071
2 Afghanistan  2000   2666   20595360
3 Brazil       1999  37737  172006362
4 Brazil       2000  80488  174504898
5 China        1999 212258 1272915272
6 China        2000 213766 1280428583
```

14. Ejercicio extra 3

Se unieron los datos de los aviones y se ordenaron por distancia total.

```
Distance_Manufacturer_model <- Distances_plane %>%
  left_join(planes, by = 'tailnum') %>%
  arrange(desc(Total_distance)) %>%
  select(tailnum, Total_distance, manufacturer, model)
head(Distance_Manufacturer_model)
```

```
# A tibble: 6 x 4
  tailnum Total_distance manufacturer model
  <chr>            <dbl> <chr>        <chr>
1 N718TW          775381 BOEING       757-231
2 N722TW          764177 BOEING       757-231
3 N721TW          756030 BOEING       757-231
4 N502UA          726276 BOEING       757-222
5 N624AG          718799 BOEING       757-2Q8
6 N505UA          716931 BOEING       757-222
```

15. Ejercicio extra 4

Se unieron los vuelos con los aviones y se calcularon los retrasos medios por fabricante, usando los valores disponibles para cada retraso.

```
retrasos <- flights %>%
  left_join(planes, by = 'tailnum') %>%
  group_by(manufacturer) %>%
  summarise(salida = mean(dep_delay, na.rm = TRUE),
            llegada = mean(arr_delay, na.rm = TRUE))

retrasos %>% arrange(desc(salida))
```

```
# A tibble: 4 x 3
  manufacturer   salida llegada
  <chr>           <dbl>   <dbl>
1 BOMBARDIER INC  18.9     8.04
2 BOEING          11.7     3.75
3 AIRBUS COMP     11.0     5.45
4 DOUGLAS          5.95    3.5
```

```
retrasos %>% arrange(desc(llegada))
```

```
# A tibble: 4 x 3
  manufacturer   salida llegada
  <chr>           <dbl>   <dbl>
1 BOMBARDIER INC  18.9     8.04
2 AIRBUS COMP     11.0     5.45
3 BOEING          11.7     3.75
4 DOUGLAS          5.95    3.5
```

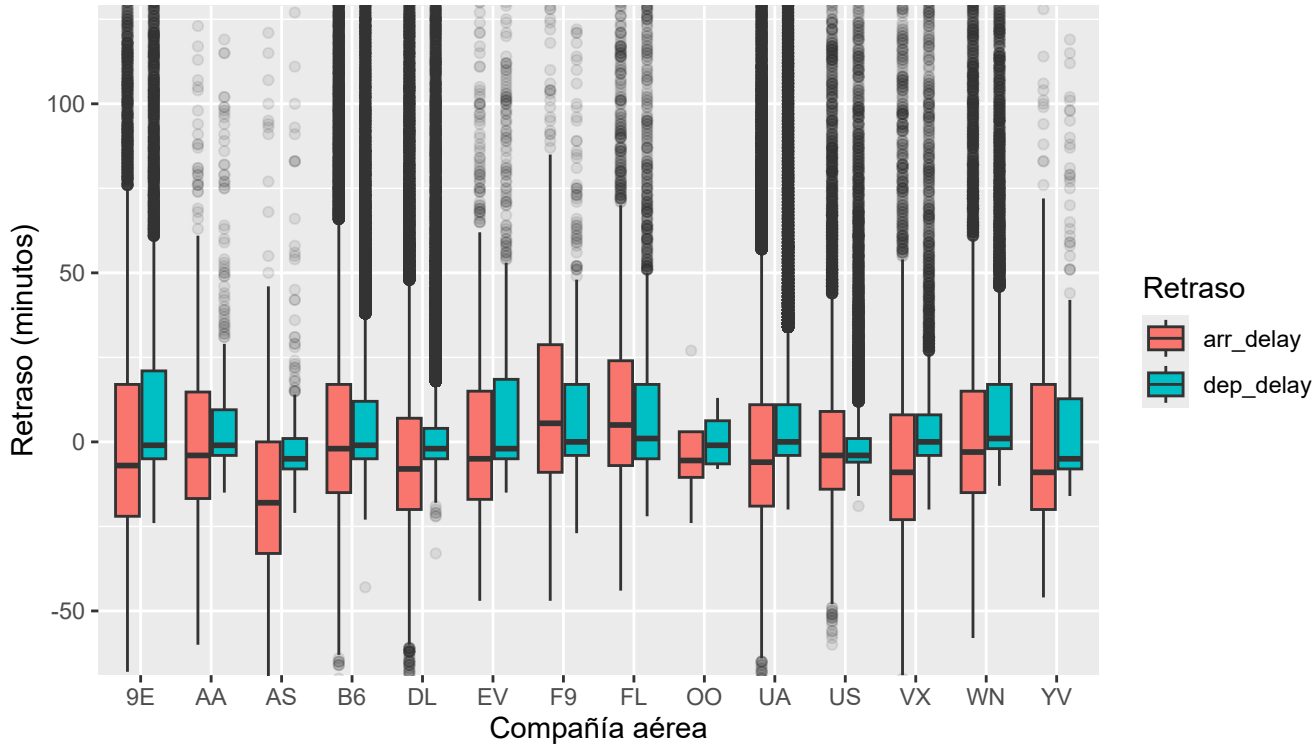
En las salidas los mayores retrasos medios son de BOMBARDIER INC y BOEING. En las llegadas son de BOMBARDIER INC y AIRBUS COMP.

16. Ejercicio extra 5

Se representaron los retrasos de salida y llegada por compañía. En los boxplots se muestra la zona entre -60 y 120 minutos para ver las cajas.

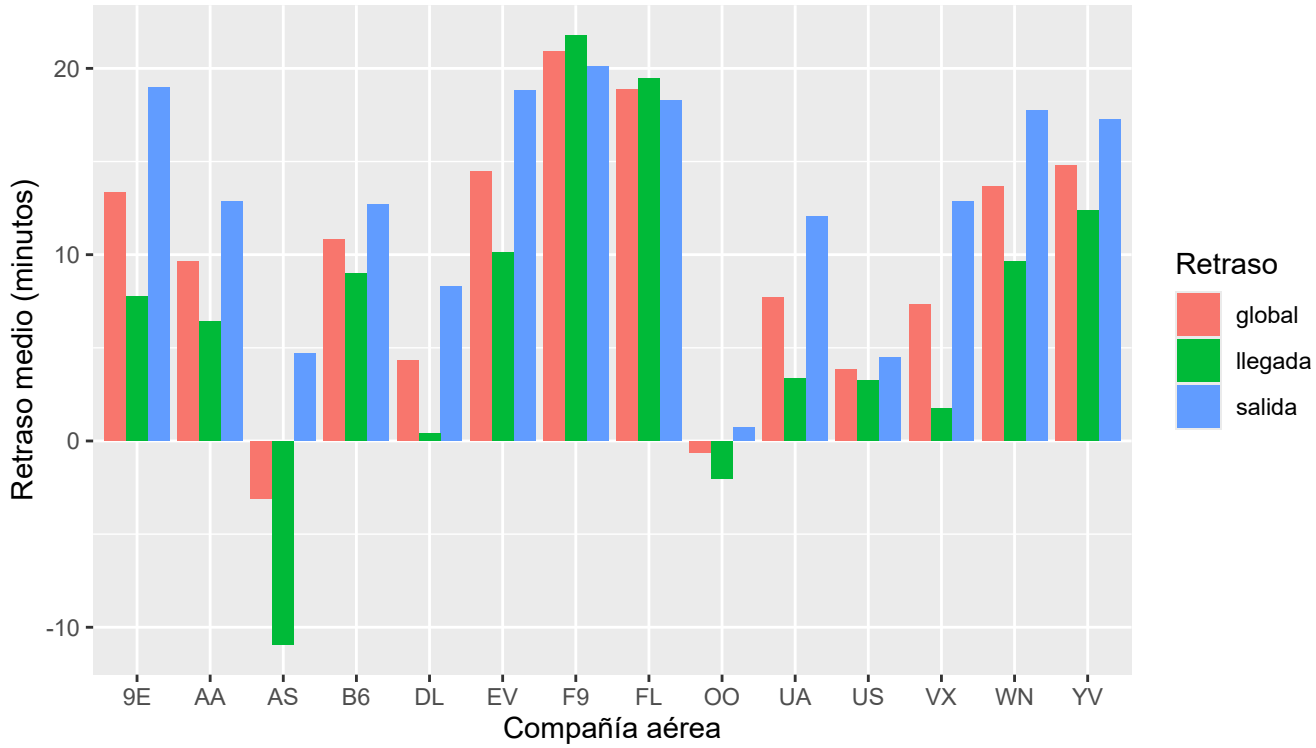
```
dir.create('Results', showWarnings = FALSE)
retrasos_largos <- flights %>%
  pivot_longer(ends_with('delay'), names_to = 'tipo',
               values_to = 'retraso', values_drop_na = TRUE)

ggplot(retrasos_largos, aes(carrier, retraso, fill = tipo)) +
  geom_boxplot(outlier.alpha = 0.1) +
  coord_cartesian(ylim = c(-60, 120)) +
  labs(x = 'Compañía aérea', y = 'Retraso (minutos)', fill = 'Retraso')
```



```r
medias <- flights %>%
  group_by(carrier) %>%
  summarise(salida = mean(dep_delay, na.rm = TRUE),
            llegada = mean(arr_delay, na.rm = TRUE)) %>%
  mutate(global = (salida + llegada) / 2) %>%
  pivot_longer(-carrier, names_to = 'tipo', values_to = 'retraso')

ggplot(medias, aes(carrier, retraso, fill = tipo)) +
  geom_col(position = 'dodge') +
  labs(x = 'Compañía aérea', y = 'Retraso medio (minutos)', fill = 'Retraso')
```



Para comparar los retrasos medios, el gráfico de barras es más adecuado; los boxplots muestran la distribución de los retrasos.