Práctica 3 y 4. Preparación y manejo de Datos

Análisis Exploratorio de Datos. Máster en Ciencia de Datos - UV

Carlos Galdámez Huertas (galhuer)

2026-10-29

Índice

1. Ejercicio 1 **1**

2. Ejercicio 2 **2**

3. Ejercicio 3 **2**

4. Ejercicio 4 **3**

5. Ejercicio 5 **4**

6. Ejercicio 6 **5**

7. Ejercicio 7 **5**

8. Ejercicio 8 **6**

9. Ejercicio 9 **6**

1. Ejercicio 1

Se agruparon los intervalos de ingresos en una columna de tipo factor y los casos en otra.

```
load('data/pew_religion.Rdata')
pew_tidy <- gather(pew_religion, income, freq, -religion, factor_key = TRUE)
head(pew_tidy)
```

```
            religion income freq
1           Agnostic  <$10k   27
2            Atheist  <$10k   12
3           Buddhist  <$10k   27
4           Catholic  <$10k  418
5 Don't know/refused  <$10k   15
6   Evangelical Prot  <$10k  575
```

2. Ejercicio 2

Se agruparon las semanas y las posiciones en dos columnas.

```
load('data/billboard.Rdata')
billboard_tidy <- pivot_longer(raw, wk1:wk76, names_to = 'week',
                               values_to = 'rank', names_prefix = 'wk')
head(billboard_tidy[, c('artist', 'week', 'rank')])
```

```
# A tibble: 6 x 3
  artist week   rank
  <chr>  <chr> <int>
1 2 Pac  1        87
2 2 Pac  2        82
3 2 Pac  3        72
4 2 Pac  4        77
5 2 Pac  5        87
6 2 Pac  6        94
```

3. Ejercicio 3

Se agruparon los casos y se separaron el sexo y la edad.

```
load('data/tb.Rdata')
tb_tidy <- raw %>%
  gather(grupo, casos, -country, -year) %>%
  separate(grupo, into = c('sexo', 'edad'), sep = 1)
head(tb_tidy)
```

```
  country year sexo edad casos
1      AD 2000    m  014     0
2      AE 2000    m  014     2
3      AF 2000    m  014    52
4      AG 2000    m  014     0
5      AL 2000    m  014     2
6      AM 2000    m  014     2
```

4. Ejercicio 4

Se agruparon los días, se creó la fecha y se separaron las temperaturas.

```
load('data/weather.Rdata')
weather_tidy <- raw %>%
  pivot_longer(d1:d31, names_to = 'dia', names_prefix = 'd',
               values_to = 'temperatura', values_drop_na = TRUE) %>%
  mutate(fecha = make_date(year, month, as.integer(dia))) %>%
  select(-year, -month, -dia) %>%
  pivot_wider(names_from = element, values_from = temperatura)
head(weather_tidy)
```

```
# A tibble: 6 x 4
  id      fecha       tmax  tmin
  <chr>   <date>     <dbl> <dbl>
1 MX17004 2010-01-30  27.8  14.5
2 MX17004 2010-02-02  27.3  14.4
3 MX17004 2010-02-03  24.1  14.4
4 MX17004 2010-02-11  29.7  13.4
5 MX17004 2010-02-23  29.9  10.7
6 MX17004 2010-03-05  32.1  14.2
```

5. Ejercicio 5

```
load('data/VuelosNY.Rdata')
head(flights)
```

```
  year month day dep_time sched_dep_time dep_delay arr_time sched_arr_time
1 2013     1   1      517            515         2      830            819
2 2013     1   1      533            529         4      850            830
3 2013     1   1      542            540         2      923            850
4 2013     1   1      544            545        -1     1004           1022
5 2013     1   1      554            600        -6      812            837
6 2013     1   1      554            558        -4      740            728
  arr_delay carrier flight tailnum origin dest air_time distance hour minute
1        11      UA   1545  N14228    EWR  IAH      227     1400    5     15
2        20      UA   1714  N24211    LGA  IAH      227     1416    5     29
3        33      AA   1141  N619AA    JFK  MIA      160     1089    5     40
4       -18      B6    725  N804JB    JFK  BQN      183     1576    5     45
5       -25      DL    461  N668DN    LGA  ATL      116      762    6      0
6        12      UA   1696  N39463    EWR  ORD      150      719    5     58
   time_hour
1 1357034400
2 1357034400
3 1357034400
4 1357034400
5 1357038000
6 1357034400
```

```
head(planes)
```

```
  tailnum year                type     manufacturer     model engines seats
1  N10156 2004 Fixed wing multi engine          EMBRAER EMB-145XR       2    55
2  N102UW 1998 Fixed wing multi engine AIRBUS INDUSTRIE  A320-214       2   182
3  N103US 1999 Fixed wing multi engine AIRBUS INDUSTRIE  A320-214       2   182
4  N104UW 1999 Fixed wing multi engine AIRBUS INDUSTRIE  A320-214       2   182
5  N10575 2002 Fixed wing multi engine          EMBRAER EMB-145LR       2    55
6  N105UW 1999 Fixed wing multi engine AIRBUS INDUSTRIE  A320-214       2   182
  speed    engine
1    NA Turbo-fan
2    NA Turbo-fan
3    NA Turbo-fan
4    NA Turbo-fan
5    NA Turbo-fan
6    NA Turbo-fan
```

`flights` contiene información de cada vuelo, como las fechas, los horarios, los retrasos y los aeropuertos. `planes` describe cada avión, incluyendo su fabricante, modelo y número de asientos.

6. Ejercicio 6

Se filtraron los aviones y se unificaron los nombres de Airbus.

```
planes.f <- planes %>%
  filter(!grepl('MCDONNELL DOUGLAS', manufacturer)) %>%
  filter(seats >= 90, seats <= 210) %>%
  mutate(manufacturer = if_else(grepl('AIRBUS', manufacturer),
                                'AIRBUS COMP', manufacturer))
head(planes.f)
```

```
  tailnum year                    type manufacturer    model engines seats
1  N102UW 1998 Fixed wing multi engine  AIRBUS COMP A320-214       2   182
2  N103US 1999 Fixed wing multi engine  AIRBUS COMP A320-214       2   182
3  N104UW 1999 Fixed wing multi engine  AIRBUS COMP A320-214       2   182
4  N105UW 1999 Fixed wing multi engine  AIRBUS COMP A320-214       2   182
5  N107US 1999 Fixed wing multi engine  AIRBUS COMP A320-214       2   182
6  N108UW 1999 Fixed wing multi engine  AIRBUS COMP A320-214       2   182
  speed    engine
1    NA Turbo-fan
2    NA Turbo-fan
3    NA Turbo-fan
4    NA Turbo-fan
5    NA Turbo-fan
6    NA Turbo-fan
```

7. Ejercicio 7

Se seleccionaron los vuelos de los aviones filtrados.

```
flights.f <- semi_join(flights, planes.f, by = 'tailnum')
head(flights.f[, c('tailnum', 'origin', 'dest')])
```

```
  tailnum origin dest
1  N14228    EWR  IAH
2  N24211    LGA  IAH
3  N619AA    JFK  MIA
4  N804JB    JFK  BQN
5  N668DN    LGA  ATL
6  N39463    EWR  ORD
```

8. Ejercicio 8

Se asignaron los datos filtrados a los nombres originales.

```
planes <- planes.f
flights <- flights.f
```

9. Ejercicio 9

Se eliminaron las variables indicadas de ambos conjuntos.

```
flights <- flights %>% select(-time_hour, -ends_with('time'))
planes <- planes %>% select(-speed, -type)
```