Práctica 5. Datos Anómalos

Análisis Exploratorio de Datos. Máster en Ciencia de Datos - UV

Carlos Galdámez Huertas (galhuer)

2026-11-03

Índice

1. Ejercicio 1 **1**

2. Ejercicio 2 **2**

3. Ejercicio 3 **2**

1. Ejercicio 1

Se inspeccionaron los datos y se ordenó cada variable de menor a mayor y de mayor a menor. Se muestran los tres primeros valores de cada orden.

```
dirty_iris <- read_csv('data/dirty_iris.csv')
if (interactive()) View(dirty_iris)

menor <- lapply(dirty_iris, sort, na.last = TRUE)
mayor <- lapply(dirty_iris, sort, decreasing = TRUE, na.last = TRUE)
data.frame(
  variable = names(dirty_iris),
  menor = sapply(menor, function(x) paste(head(x, 3), collapse = ', ')),
  mayor = sapply(mayor, function(x) paste(head(x, 3), collapse = ', ')),
  faltantes = colSums(is.na(dirty_iris)), row.names = NULL
)
```

```
      variable                  menor                          mayor faltantes
1 Sepal.Length            0, 4.3, 4.4                   73, 49, 7.9        10
2  Sepal.Width             -3, 0, 2.2                   30, 29, 4.2        17
3 Petal.Length         0, 0.82, 0.925                    63, 23, 14        19
4  Petal.Width          0.1, 0.1, 0.1                  Inf, 2.5, 2.5        12
5      Species setosa, setosa, setosa virginica, virginica, virginica         0
```

Hay valores ausentes, medidas iguales a cero, una medida negativa (-3) y un valor infinito. También destacan valores altos como 73, 30 y 63.

2. Ejercicio 2

Se sustituyeron por `NA` los valores especiales y las medidas menores o iguales a cero.

```
dirty_iris <- dirty_iris %>%
  mutate(across(where(is.numeric),
                ~ ifelse(!is.finite(.x) | .x <= 0, NA, .x)))
colSums(is.na(dirty_iris))
```

```
Sepal.Length  Sepal.Width Petal.Length  Petal.Width      Species
          11           19           20           13            0
```

3. Ejercicio 3

Se calcularon las observaciones completas y se guardaron en `clean_iris`.

```
completas <- complete.cases(dirty_iris)
data.frame(numero = sum(completas), porcentaje = mean(completas) * 100)
```

```
  numero porcentaje
1     92   61.33333
```

```
clean_iris <- na.omit(dirty_iris)
```