Práctica 5. Datos Anómalos

Análisis Exploratorio de Datos. Máster en Ciencia de Datos - UV

Carlos Galdámez Huertas (galhuer)

2026-11-03

Índice

1. Ejercicio 1 **2**

2. Ejercicio 2 **2**

3. Ejercicio 3 **3**

4. Ejercicio 4 **4**

5. Ejercicio 5 **5**

6. Ejercicio 6 **5**

7. Ejercicio 7 **6**

8. Ejercicio 8 **7**

9. Ejercicio 9 **8**

10. Ejercicio 10 **9**

1. Ejercicio 1

Se inspeccionaron los datos y se ordenó cada variable de menor a mayor y de mayor a menor. Se muestran los tres primeros valores de cada orden.

```
dirty_iris <- read_csv('data/dirty_iris.csv')
if (interactive()) View(dirty_iris)

menor <- lapply(dirty_iris, sort, na.last = TRUE)
mayor <- lapply(dirty_iris, sort, decreasing = TRUE, na.last = TRUE)
data.frame(
  variable = names(dirty_iris),
  menor = sapply(menor, function(x) paste(head(x, 3), collapse = ', ')),
  mayor = sapply(mayor, function(x) paste(head(x, 3), collapse = ', ')),
  faltantes = colSums(is.na(dirty_iris)), row.names = NULL
)
```

```
      variable                  menor                          mayor faltantes
1 Sepal.Length            0, 4.3, 4.4                   73, 49, 7.9        10
2  Sepal.Width             -3, 0, 2.2                   30, 29, 4.2        17
3 Petal.Length         0, 0.82, 0.925                    63, 23, 14        19
4  Petal.Width           0.1, 0.1, 0.1                 Inf, 2.5, 2.5        12
5      Species setosa, setosa, setosa virginica, virginica, virginica         0
```

Hay valores ausentes, medidas iguales a cero, una medida negativa (-3) y un valor infinito. También destacan valores altos como 73, 30 y 63.

2. Ejercicio 2

Se sustituyeron por `NA` los valores especiales y las medidas menores o iguales a cero.

```
dirty_iris <- dirty_iris %>%
  mutate(across(where(is.numeric),
                ~ ifelse(!is.finite(.x) | .x <= 0, NA, .x)))
colSums(is.na(dirty_iris))
```

```
Sepal.Length  Sepal.Width Petal.Length  Petal.Width      Species
          11           19           20           13            0
```

3. Ejercicio 3

Se calcularon las observaciones completas y se guardaron en `clean_iris`.

```
completas <- complete.cases(dirty_iris)
data.frame(numero = sum(completas), porcentaje = mean(completas) * 100)
```

```
  numero porcentaje
1     92   61.33333
```

```
clean_iris <- na.omit(dirty_iris)
```

4. Ejercicio 4

Se calcularon los estadísticos para los dos conjuntos, sin contar los valores perdidos.

```
madm <- function(x) {
  1.4826 * median(abs(x - median(x, na.rm = TRUE)), na.rm = TRUE)
}

estadisticos <- list(
  media = ~ mean(.x, na.rm = TRUE),
  sd = ~ sd(.x, na.rm = TRUE),
  mediana = ~ median(.x, na.rm = TRUE),
  madm = madm,
  iqr = ~ IQR(.x, na.rm = TRUE)
)

resumen <- bind_rows(dirty = dirty_iris, clean = clean_iris, .id = 'datos') %>%
  group_by(datos) %>%
  summarise(across(where(is.numeric), estadisticos), .groups = 'drop') %>%
  pivot_longer(-datos, names_to = c('variable', '.value'), names_sep = '_')
resumen
```

```
# A tibble: 8 x 7
  datos variable     media    sd mediana  madm   iqr
  <chr> <chr>        <dbl> <dbl>   <dbl> <dbl> <dbl>
1 clean Sepal.Length  6.37 4.57      5.8 1.04    1.3
2 clean Sepal.Width   3.33 2.84      3   0.371   0.5
3 clean Petal.Length  4.16 2.88      4.5 1.63    3.6
4 clean Petal.Width   1.22 0.765     1.4 0.890   1.6
5 dirty Sepal.Length  6.61 6.80      5.8 1.04    1.3
6 dirty Sepal.Width   3.47 3.28      3   0.297   0.5
7 dirty Petal.Length  4.48 5.78      4.5 1.63    3.5
8 dirty Petal.Width   1.21 0.765     1.3 1.04    1.5
```

Para `Petal.Length`, la media es 4,48 en `dirty_iris` y 4,16 en `clean_iris`. La desviación típica baja de 5,78 a 2,88; la mediana y la MADM coinciden y el IQR pasa de 3,5 a 3,6.

5. Ejercicio 5

Se definieron las cuatro reglas para identificar valores atípicos.

```
reglasigma <- function(x) {
  abs(x - mean(x, na.rm = TRUE)) > 3 * sd(x, na.rm = TRUE)
}

reglahampel <- function(x) {
  abs(x - median(x, na.rm = TRUE)) > 3 * madm(x)
}

reglaboxplot <- function(x) {
  cuartiles <- quantile(x, c(0.25, 0.75), na.rm = TRUE)
  rango <- diff(cuartiles)
  x < cuartiles[1] - 1.5 * rango | x > cuartiles[2] + 1.5 * rango
}

reglapercentil <- function(x) {
  limites <- quantile(x, c(0.05, 0.95), na.rm = TRUE)
  x < limites[1] | x > limites[2]
}
```

6. Ejercicio 6

Se aplicaron las cuatro reglas a `Petal.Length` y se creó una columna por método.

```
dirty_iris <- dirty_iris %>%
  mutate(across(Petal.Length,
                list(sigma = reglasigma, hampel = reglahampel,
                     boxplot = reglaboxplot, percentil = reglapercentil),
                .names = '{.fn}'))
head(dirty_iris %>% select(Petal.Length, sigma, hampel, boxplot, percentil))
```

```
# A tibble: 6 x 5
  Petal.Length sigma hampel boxplot percentil
         <dbl> <lgl> <lgl>  <lgl>   <lgl>
1          4.5 FALSE FALSE  FALSE   FALSE
2          6   FALSE FALSE  FALSE   FALSE
3          5.4 FALSE FALSE  FALSE   FALSE
4          1.6 FALSE FALSE  FALSE   FALSE
5          3.5 FALSE FALSE  FALSE   FALSE
6         NA   NA    NA     NA      NA
```

7. Ejercicio 7

Se contaron los valores atípicos y se ordenaron por método.

```
conteos <- dirty_iris %>%
  summarise(across(c(sigma, hampel, boxplot, percentil),
                   ~ sum(.x, na.rm = TRUE)))
conteos
```

```
# A tibble: 1 x 4
  sigma hampel boxplot percentil
  <int>  <int>   <int>     <int>
1     2      3       3        11
```

```
valores <- dirty_iris %>%
  select(Petal.Length, sigma, hampel, boxplot, percentil) %>%
  pivot_longer(-Petal.Length, names_to = 'metodo', values_to = 'atipico') %>%
  filter(atipico) %>%
  arrange(metodo, Petal.Length) %>%
  select(metodo, Petal.Length)
print(valores, n = Inf)
```

```
# A tibble: 19 x 2
   metodo    Petal.Length
   <chr>            <dbl>
 1 boxplot             14
 2 boxplot             23
 3 boxplot             63
 4 hampel              14
 5 hampel              23
 6 hampel              63
 7 percentil            0.82
 8 percentil            0.925
 9 percentil            1.1
10 percentil            1.2
11 percentil            6.6
12 percentil            6.7
13 percentil            6.7
14 percentil            6.9
15 percentil           14
16 percentil           23
17 percentil           63
18 sigma               23
19 sigma               63
```

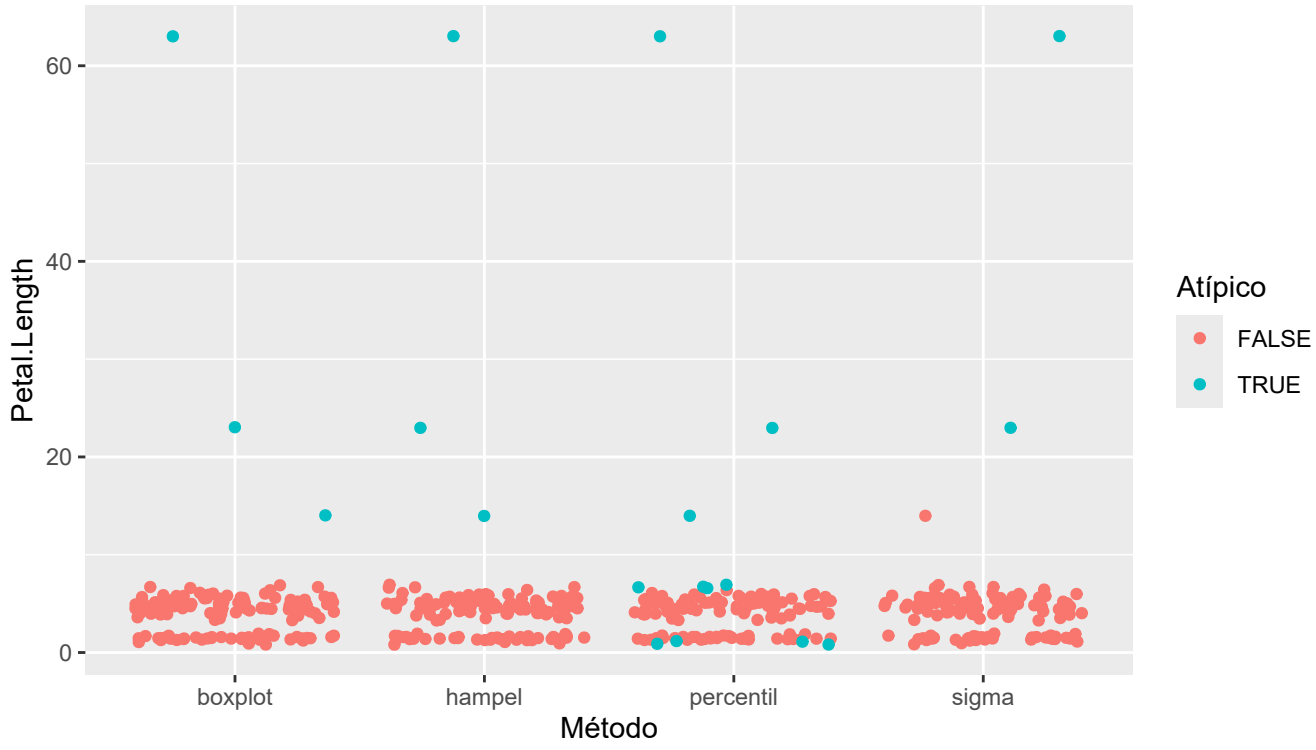
El método de percentiles detecta más valores atípicos; Hampel y boxplot identifican los mismos.

8. Ejercicio 8

Se representaron las medidas de `Petal.Length` y los valores atípicos de cada método en distinto color.

```
dir.create('Results', showWarnings = FALSE)
datos_grafico <- dirty_iris %>%
  select(Petal.Length, sigma, hampel, boxplot, percentil) %>%
  pivot_longer(-Petal.Length, names_to = 'metodo', values_to = 'atipico') %>%
  filter(!is.na(Petal.Length)) %>%
  arrange(atipico)

set.seed(123)
ggplot(datos_grafico, aes(metodo, Petal.Length, color = atipico)) +
  geom_point(position = 'jitter') +
  labs(x = 'Método', y = 'Petal.Length', color = 'Atípico')
```



9. Ejercicio 9

Se rellenaron los valores ausentes con la media general y con la media de cada especie, en dos columnas nuevas.

```
dirty_iris <- dirty_iris %>%
  mutate(Petal.Length1 = ifelse(is.na(Petal.Length),
                                mean(Petal.Length, na.rm = TRUE), Petal.Length)) %>%
  group_by(Species) %>%
  mutate(Petal.Length2 = ifelse(is.na(Petal.Length),
                                mean(Petal.Length, na.rm = TRUE), Petal.Length)) %>%
  ungroup()

head(dirty_iris %>%
       filter(is.na(Petal.Length)) %>%
       select(Species, Petal.Length, Petal.Length1, Petal.Length2))
```

```
# A tibble: 6 x 4
  Species    Petal.Length Petal.Length1 Petal.Length2
  <chr>             <dbl>         <dbl>         <dbl>
1 setosa               NA          4.48          1.80
2 setosa               NA          4.48          1.80
3 setosa               NA          4.48          1.80
4 virginica            NA          4.48          6.80
5 setosa               NA          4.48          1.80
6 versicolor           NA          4.48          4.55
```

10. Ejercicio 10

Se aplicaron las reglas a `Petal.Length2` y se compararon las imputaciones, excluyendo los valores atípicos según la regla del percentil.

```
dirty_iris <- dirty_iris %>%
  mutate(across(Petal.Length2,
                list(sigma = reglasigma, hampel = reglahampel,
                     boxplot = reglaboxplot, percentil = reglapercentil),
                .names = '{.fn}2'))

head(dirty_iris %>% select(Petal.Length2, sigma2, hampel2, boxplot2, percentil2))
```

```
# A tibble: 6 x 5
  Petal.Length2 sigma2 hampel2 boxplot2 percentil2
          <dbl> <lgl>  <lgl>   <lgl>    <lgl>
1           4.5 FALSE  FALSE   FALSE    FALSE
2           6   FALSE  FALSE   FALSE    FALSE
3           5.4 FALSE  FALSE   FALSE    FALSE
4           1.6 FALSE  FALSE   FALSE    FALSE
5           3.5 FALSE  FALSE   FALSE    FALSE
6           1.80 FALSE  FALSE   FALSE    FALSE
```

```
dirty_iris %>%
  filter(!percentil2) %>%
  ggplot(aes(Petal.Length1, Petal.Length2, color = is.na(Petal.Length))) +
  geom_point() +
  labs(color = 'Imputado')
```

