Práctica 5. Datos Anómalos

Análisis Exploratorio de Datos. Máster en Ciencia de Datos - UV

Carlos Galdámez Huertas (galhuer)

2026-11-03

Índice

1. Ejercicio 1 **1**

2. Ejercicio 2 **2**

3. Ejercicio 3 **2**

4. Ejercicio 4 **3**

5. Ejercicio 5 **4**

1. Ejercicio 1

Se inspeccionaron los datos y se ordenó cada variable de menor a mayor y de mayor a menor. Se muestran los tres primeros valores de cada orden.

```
dirty_iris <- read_csv('data/dirty_iris.csv')
if (interactive()) View(dirty_iris)

menor <- lapply(dirty_iris, sort, na.last = TRUE)
mayor <- lapply(dirty_iris, sort, decreasing = TRUE, na.last = TRUE)
data.frame(
  variable = names(dirty_iris),
  menor = sapply(menor, function(x) paste(head(x, 3), collapse = ', ')),
  mayor = sapply(mayor, function(x) paste(head(x, 3), collapse = ', ')),
  faltantes = colSums(is.na(dirty_iris)), row.names = NULL
)
```

```
      variable                  menor                          mayor faltantes
1 Sepal.Length            0, 4.3, 4.4                   73, 49, 7.9        10
2  Sepal.Width             -3, 0, 2.2                   30, 29, 4.2        17
3 Petal.Length         0, 0.82, 0.925                    63, 23, 14        19
4  Petal.Width          0.1, 0.1, 0.1                  Inf, 2.5, 2.5        12
5      Species setosa, setosa, setosa virginica, virginica, virginica         0
```

Hay valores ausentes, medidas iguales a cero, una medida negativa (-3) y un valor infinito. También destacan valores altos como 73, 30 y 63.

2. Ejercicio 2

Se sustituyeron por `NA` los valores especiales y las medidas menores o iguales a cero.

```
dirty_iris <- dirty_iris %>%
  mutate(across(where(is.numeric),
                ~ ifelse(!is.finite(.x) | .x <= 0, NA, .x)))
colSums(is.na(dirty_iris))
```

```
Sepal.Length  Sepal.Width Petal.Length  Petal.Width      Species
          11           19           20           13            0
```

3. Ejercicio 3

Se calcularon las observaciones completas y se guardaron en `clean_iris`.

```
completas <- complete.cases(dirty_iris)
data.frame(numero = sum(completas), porcentaje = mean(completas) * 100)
```

```
  numero porcentaje
1     92   61.33333
```

```
clean_iris <- na.omit(dirty_iris)
```

4. Ejercicio 4

Se calcularon los estadísticos para los dos conjuntos, sin contar los valores perdidos.

```
madm <- function(x) {
  1.4826 * median(abs(x - median(x, na.rm = TRUE)), na.rm = TRUE)
}

estadisticos <- list(
  media = ~ mean(.x, na.rm = TRUE),
  sd = ~ sd(.x, na.rm = TRUE),
  mediana = ~ median(.x, na.rm = TRUE),
  madm = madm,
  iqr = ~ IQR(.x, na.rm = TRUE)
)

resumen <- bind_rows(dirty = dirty_iris, clean = clean_iris, .id = 'datos') %>%
  group_by(datos) %>%
  summarise(across(where(is.numeric), estadisticos), .groups = 'drop') %>%
  pivot_longer(-datos, names_to = c('variable', '.value'), names_sep = '_')
resumen
```

```
# A tibble: 8 x 7
  datos variable     media    sd mediana  madm   iqr
  <chr> <chr>        <dbl> <dbl>   <dbl> <dbl> <dbl>
1 clean Sepal.Length  6.37 4.57      5.8 1.04    1.3
2 clean Sepal.Width   3.33 2.84      3   0.371   0.5
3 clean Petal.Length  4.16 2.88      4.5 1.63    3.6
4 clean Petal.Width   1.22 0.765     1.4 0.890   1.6
5 dirty Sepal.Length  6.61 6.80      5.8 1.04    1.3
6 dirty Sepal.Width   3.47 3.28      3   0.297   0.5
7 dirty Petal.Length  4.48 5.78      4.5 1.63    3.5
8 dirty Petal.Width   1.21 0.765     1.3 1.04    1.5
```

Para `Petal.Length`, la media es 4,48 en `dirty_iris` y 4,16 en `clean_iris`. La desviación típica baja de 5,78 a 2,88; la mediana y la MADM coinciden y el IQR pasa de 3,5 a 3,6.

5. Ejercicio 5

Se definieron las cuatro reglas para identificar valores atípicos.

```
reglasigma <- function(x) {
  abs(x - mean(x, na.rm = TRUE)) > 3 * sd(x, na.rm = TRUE)
}

reglahampel <- function(x) {
  abs(x - median(x, na.rm = TRUE)) > 3 * madm(x)
}

reglaboxplot <- function(x) {
  cuartiles <- quantile(x, c(0.25, 0.75), na.rm = TRUE)
  rango <- diff(cuartiles)
  x < cuartiles[1] - 1.5 * rango | x > cuartiles[2] + 1.5 * rango
}

reglapercentil <- function(x) {
  limites <- quantile(x, c(0.05, 0.95), na.rm = TRUE)
  x < limites[1] | x > limites[2]
}
```