Tema 4. Ejercicios de texto

Carlos Galdámez Huertas (galhuer)

2026-10-28

Índice

1. Nombres de cpus **1**

2. Correos de la UV **1**

3. La Celestina **2**

4. Caracteres de El Lazarillo **2**

5. Texto y expresiones regulares **3**

1. Nombres de cpus

Se buscaron los nombres que no contienen las letras a, e o i.

```
data('cpus', package = 'MASS', envir = environment())
nombres <- as.character(cpus$name)
nombres[!grepl('[aei]', nombres, ignore.case = TRUE)]
```

```
 [1] "BURROUGHS B1955" "BURROUGHS B2900" "BURROUGHS B2925" "BURROUGHS B4955"
 [5] "BURROUGHS B5900" "BURROUGHS B5920" "BURROUGHS B6900" "BURROUGHS B6925"
 [9] "C.R.D. 68/10-80" "HP 3000/30"      "HP 3000/40"      "HP 3000/44"
[13] "HP 3000/48"      "HP 3000/64"      "HP 3000/88"      "NCR V8635 "
[17] "NCR V8650"       "NCR V8635"       "NCR V8665"       "NCR V8670"
```

2. Correos de la UV

Se comprobó la expresión en regex101 con direcciones de prueba. Ver captura.

```
correos_uv <- c('paco5@alumni.uv.es', 'vifranjo@uv.es',
                'martsobm@uv.es', 'pascal@gmail.com', 'ménfor@alumni.es')
patron_uv <- '^[A-Za-z0-9._%+-]+@(alumni\\.)?uv\\.es$'
data.frame(correo = correos_uv, valido = grepl(patron_uv, correos_uv))
```

```
              correo valido
1 paco5@alumni.uv.es   TRUE
2     vifranjo@uv.es   TRUE
3     martsobm@uv.es   TRUE
4   pascal@gmail.com  FALSE
5   ménfor@alumni.es  FALSE
```

3. La Celestina

Desde la línea 265, la palabra más frecuente es `que` y la vocal más frecuente es `e` sin acento. Se menciona más a Calisto que a Melibea.

```
lineas <- readLines('data/LaCelestina.txt', encoding = 'UTF-8', warn = FALSE)
texto <- tolower(paste(lineas[265:length(lineas)], collapse = ' '))
palabras <- str_extract_all(texto, '\\p{L}+')[[1]]
head(sort(table(palabras), decreasing = TRUE))
```

```
palabras
 que   de    e   la    a   en
4381 4197 2324 2253 1918 1886
```

```
vocales <- str_extract_all(texto, '[aáeéiíoóuúü]')[[1]]
table(factor(vocales, levels = c('a','á','e','é','i','í','o','ó','u','ú','ü')))
```

```
    a     á     e     é     i     í     o     ó     u     ú     ü
63219     0 70116     0 29824     0 45694     0 23927     0     0
```

```
table(factor(palabras[palabras %in% c('calisto', 'melibea')],
             levels = c('calisto', 'melibea')))
```

```
calisto melibea
    168     157
```

4. Caracteres de El Lazarillo

Se contaron todos los caracteres, distinguiendo mayúsculas y minúsculas. Los saltos de línea y espacios se identifican en las etiquetas.

```
archivo <- 'data/lazarillo.txt'
con <- file(archivo, 'rb')
texto <- readChar(con, file.info(archivo)$size, useBytes = TRUE)
close(con)
Encoding(texto) <- 'UTF-8'
texto <- sub('^\ufeff', '', texto)
caracteres <- strsplit(texto, '', fixed = TRUE)[[1]]
freq <- as.data.frame(table(caracteres))
```

```
names(freq) <- c('caracter', 'frecuencia')
freq$etiqueta <- recode(as.character(freq$caracter),
                        ' ' = '[espacio]', '\r' = '[retorno]', '\n' = '[salto]')
head(freq[order(-freq$frecuencia), c('etiqueta', 'frecuencia')], 10)
```

```
    etiqueta frecuencia
3  [espacio]      21356
49         e      12332
40         a      11296
74         o       8990
83         s       6264
71         n       6231
81         r       5868
67         l       5040
60         i       4662
47         d       4453
```

```
original <- ggplot(freq, aes(x = etiqueta, y = frecuencia)) +
  geom_col() + coord_flip() + labs(x = 'Carácter', y = 'Frecuencia')
ordenado <- ggplot(freq, aes(x = reorder(etiqueta, frecuencia), y = frecuencia)) +
  geom_col() + coord_flip() + labs(x = 'Carácter', y = 'Frecuencia')
ggsave('resultados/Lazarillo.pdf', original, width = 9, height = 18)
ggsave('resultados/Lazarillo_ordenado.pdf', ordenado, width = 9, height = 18)
```

Gráfico de caracteres y gráfico ordenado.

5. Texto y expresiones regulares

Se eliminaron `#` y `@`, se extrajeron etiquetas y se contaron las palabras.

```
tw <- c(
  paste0('Nunca olvides que... ¡la vida es un carnaval!\n',
         'Never forguet that... ¡life is a carnival!\n',
         '#Carnaval #Carnival... https://t.co/pRjgvNf8DZ'),
  paste0('\U0001f4c6Evento #fallas | Visita de la fallera mayor ',
         'y corte de honor a la Ciudad del Artista Fallero en'),
  paste0('RT @PacmaValencia: "De nuevo la tauromaquia impregnará de ',
         'sufrimiento y muerte las #fallas. De nuevo la tauromaquia ',
         'se apropiará de nuestra...'),
  paste0('RT @SimarroFerret_: #Marzo es el #mesdelapaella por excelencia. ',
         'Por eso hemos preparado para ti esta gran #oferta. ',
         'Pasa por nuestras #ferre...'),
  paste0('RT @AirNostrumLAM: #Valencia en marzo es sinónimo de pólvora, ',
         'fuego, música y fiesta. Disfruta cada día de la espectacular ',
         '#Mascletá y prep...')
)
tw_sin_simbolos <- gsub('#|@', '', tw)
cat(strwrap(tw_sin_simbolos[1], width = 70), sep = '\n')
```

```
Nunca olvides que... ¡la vida es un carnaval! Never forguet that... ¡life
is a carnival! Carnaval Carnival... https://t.co/pRjgvNf8DZ
```

```
str_extract_all(tw, '[#@][\\p{L}0-9_]+')
```

```
[[1]]
[1] "#Carnaval" "#Carnival"

[[2]]
[1] "#fallas"

[[3]]
[1] "@PacmaValencia" "#fallas"

[[4]]
[1] "@SimarroFerret_" "#Marzo"          "#mesdelapaella"  "#oferta"
[5] "#ferre"

[[5]]
[1] "@AirNostrumLAM" "#Valencia"      "#Mascletá"
```

```
tw_sin_puntuacion <- str_replace_all(tw, '[[:punct:]]', ' ')
palabras_tw <- unlist(str_extract_all(tw_sin_puntuacion, '[[:alnum:]]+'))
head(sort(table(palabras_tw), decreasing = TRUE), 10)
```

```
palabras_tw
    de     la      y     es     RT      a     De     en fallas  nuevo
     6      6      4      3      3      2      2      2      2      2
```

Se extrajeron los correos de ejemplo por dominio y los terminados en `.com` o `.net` del texto.

```
texto_correos <- paste(c('hola@.net', 'direccion@.es',
  'munge@yahoo.com', 'gommix@att.net', 'lamprecht@mac.com',
  'mstrout@att.net', 'Lukka@outlook.com', 'burniske@optonline.net',
  'isaacson@verizon.net', 'cgreuter@gmail.com', 'uncled@me.com',
  'jsnover@verizon.net', 'dinther@hotmail.com', 'jshearer@sbcglobal.net',
  'Esto@nolodebe.detectar'), collapse = '\n')
patron_correo <- '[A-Za-z0-9._%+-]+@[A-Za-z0-9.-]+\\.(com|net)\\b'
todos <- str_extract_all(texto_correos, patron_correo)[[1]]
todos[grepl('\\.net$', todos)]
```

```
[1] "gommix@att.net"         "mstrout@att.net"        "burniske@optonline.net"
[4] "isaacson@verizon.net"   "jsnover@verizon.net"    "jshearer@sbcglobal.net"
```

```
todos[grepl('@outlook\\.com$', todos)]
```

```
[1] "Lukka@outlook.com"
```

```
todos[grepl('@(gmail|yahoo)\\.com$', todos)]
```

```
[1] "munge@yahoo.com"    "cgreuter@gmail.com"
```

```
todos[grepl('@(gmail\\.com|verizon\\.net)$', todos)]
```

```
[1] "isaacson@verizon.net" "cgreuter@gmail.com"   "jsnover@verizon.net"
```

```
todos
```

```
 [1] "munge@yahoo.com"        "gommix@att.net"         "lamprecht@mac.com"
 [4] "mstrout@att.net"        "Lukka@outlook.com"      "burniske@optonline.net"
 [7] "isaacson@verizon.net"   "cgreuter@gmail.com"     "uncled@me.com"
[10] "jsnover@verizon.net"    "dinther@hotmail.com"    "jshearer@sbcglobal.net"
```

\\w identifica letras, números y guion bajo; \\W, los demás caracteres. El punto busca un carácter y .+ una secuencia. grep selecciona textos con signos de puntuación y str_locate_all() devuelve sus posiciones.

```
lengths(str_extract_all(tw, '\\W'))
```

```
[1] 31 21 26 29 29
```

```
lengths(str_extract_all(tw, '\\w+'))
```

```
[1] 21 18 21 21 22
```

```
lengths(str_extract_all(tw, '.'))
```

```
[1] 127  96 140 140 140
```

```
lengths(str_extract_all(tw, '.+'))
```

```
[1] 3 1 1 1 1
```

```
length(grep('[[:punct:]]', tw, value = TRUE))
```

```
[1] 5
```

```
lapply(str_locate_all(tw, '[[:punct:]]'), head, 3)
```

```
[[1]]
     start end
[1,]    18  18
[2,]    20  20
[3,]    43  43

[[2]]
     start end
[1,]     9   9

[[3]]
     start end
```

```
[1,]     4   4
[2,]    18  18
[3,]    20  20

[[4]]
     start end
[1,]     4   4
[2,]    18  18
[3,]    19  19

[[5]]
     start end
[1,]     4   4
[2,]    18  18
[3,]    20  20
```