Tema 5. Ejercicios de manejo de datos

Carlos Galdámez Huertas (galhuer)

2026-10-28

Índice

1. Nuevas variables con mutate **1**

2. Hora de llegada de los vuelos **2**

3. Caudal de los ríos **2**

4. Transformación de iris **3**

5. Fecundidad entre 1945 y 2025 **3**

6. Resumen de Gapminder **4**

7. Formato largo y ancho **5**

8. Transformaciones con across **6**

9. Tabla de estadísticos **7**

1. Nuevas variables con mutate

Se calcularon la suma y la media de las dos variables del ejemplo.

```
mydata <- data.frame(x1 = c(2, 2, 6, 4), x2 = c(3, 4, 2, 8))
mydata %>% mutate(sumx = x1 + x2, meanx = (x1 + x2) / 2)
```

```
  x1 x2 sumx meanx
1  2  3    5   2.5
2  2  4    6   3.0
3  6  2    8   4.0
4  4  8   12   6.0
```

2. Hora de llegada de los vuelos

Se busca cada ciudad en `world.cities` y se obtiene su zona horaria con `lutz`. Si hay nombres repetidos, se elige la localidad más poblada.

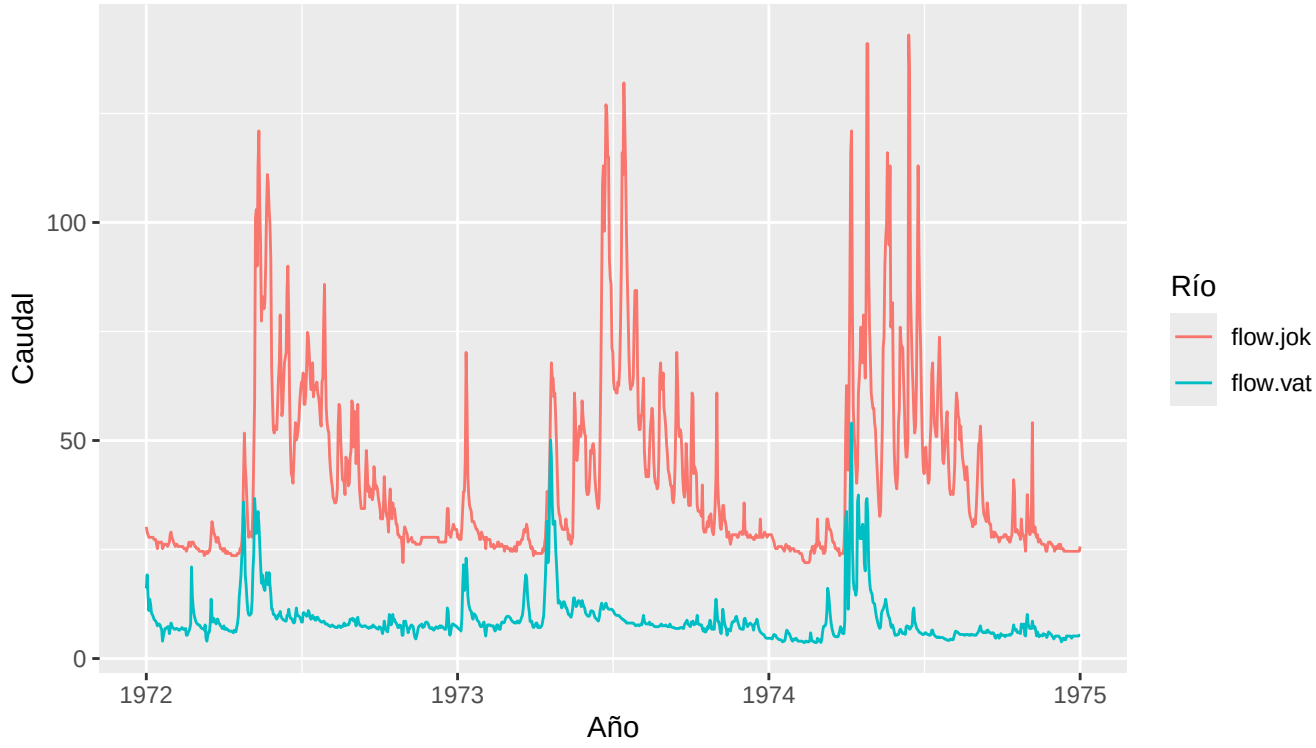
```
vuelos <- data.frame(destino = c('Sydney', 'Buenos Aires', 'Honolulu'),
                     duracion = c(22, 13, 15))
data(world.cities, package = 'maps', envir = environment())
ciudades <- world.cities[order(world.cities$pop, decreasing = TRUE), ]
pos <- match(vuelos$destino, ciudades$name)
stopifnot(!anyNA(pos))
vuelos$pais <- ciudades$country.etc[pos]
vuelos$zona <- lutz::tz_lookup_coords(ciudades$lat[pos], ciudades$long[pos],
                                      method = 'accurate')
salida <- as.POSIXct('2023-02-23 22:30', tz = 'Europe/Madrid')
vuelos$llegada <- mapply(function(h, zona) {
  format(salida + h * 3600, '%d-%m-%Y %H:%M', tz = zona)
}, vuelos$duracion, vuelos$zona, USE.NAMES = FALSE)
knitr::kable(vuelos, row.names = FALSE)
```

destino	duracion	pais	zona	llegada
Sydney	22	Australia	Australia/Sydney	25-02-2023 06:30
Buenos Aires	13	Argentina	America/Argentina/Buenos_Aires	24-02-2023 07:30
Honolulu	15	USA	Pacific/Honolulu	24-02-2023 02:30

3. Caudal de los ríos

Se pasó el conjunto a formato largo y se representaron los dos caudales.

```
load('data/iceRiver.RData')
ice.river.df %>%
  pivot_longer(c(flow.vat, flow.jok), names_to = 'rio', values_to = 'caudal') %>%
  ggplot(aes(x = time, y = caudal, colour = rio)) +
  geom_line() + labs(x = 'Año', y = 'Caudal', colour = 'Río')
```



4. Transformación de iris

Las columnas quedaron en el orden pedido: parte, medida, valor y especie.

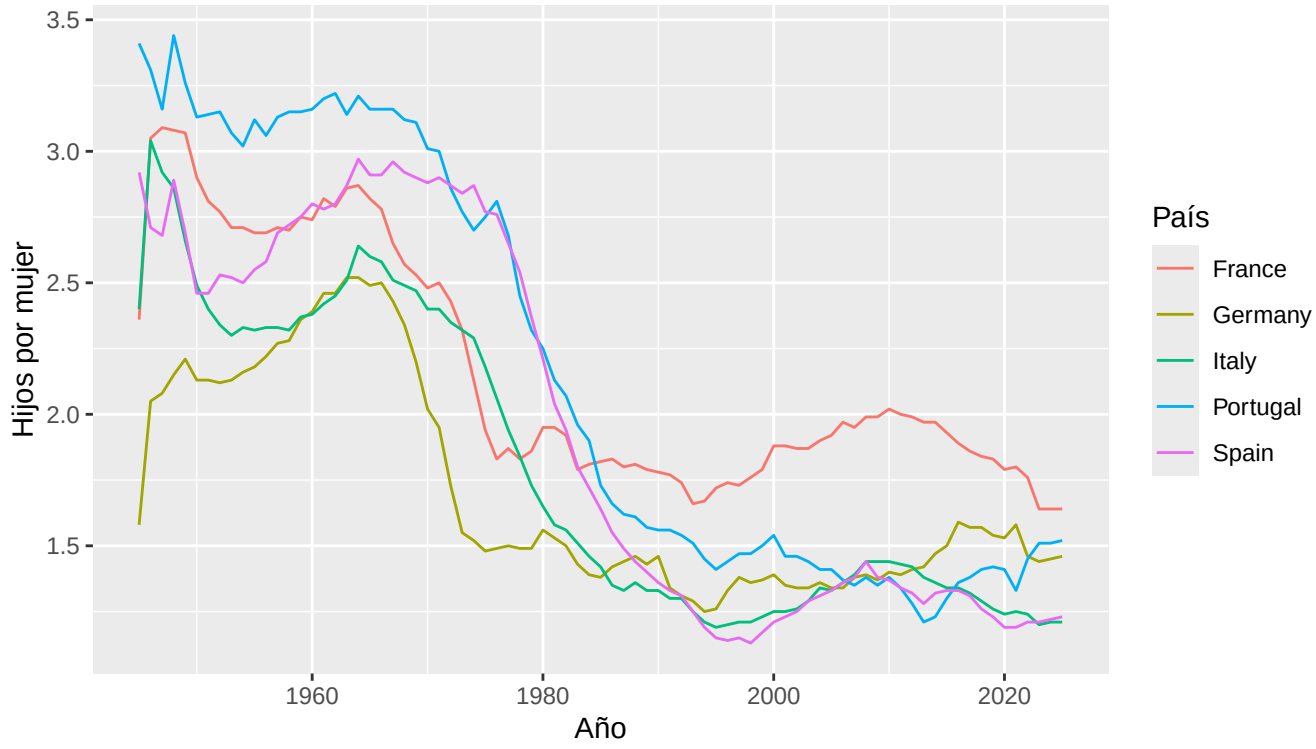
```
iris.tidy <- iris %>%
  pivot_longer(-Species, names_to = c('ParteFlor', 'TipoMedida'),
               names_sep = '\\.', values_to = 'Valor') %>%
  rename(Especie = Species) %>%
  select(ParteFlor, TipoMedida, Valor, Especie)
head(iris.tidy)
```

```
# A tibble: 6 x 4
  ParteFlor TipoMedida Valor Especie
  <chr>     <chr>      <dbl> <fct>
1 Sepal     Length       5.1 setosa
2 Sepal     Width        3.5 setosa
3 Petal     Length       1.4 setosa
4 Petal     Width        0.2 setosa
5 Sepal     Length       4.9 setosa
6 Sepal     Width        3   setosa
```

5. Fecundidad entre 1945 y 2025

Se observan repuntes en varios países a mediados del siglo XX. La serie mide hijos por mujer, no el número total de nacimientos.

```r
fertilidad <- read.csv('data/children_per_woman_total_fertility.csv',
                       check.names = FALSE)
paises <- c('Spain', 'France', 'Germany', 'Portugal', 'Italy')
fertilidad_larga <- fertilidad %>%
  filter(country %in% paises) %>%
  pivot_longer(all_of(as.character(1945:2025)), names_to = 'anio',
               values_to = 'hijos', names_transform = list(anio = as.integer))
ggplot(fertilidad_larga, aes(x = anio, y = hijos, colour = country)) +
  geom_line() + labs(x = 'Año', y = 'Hijos por mujer', colour = 'País')
```



6. Resumen de Gapminder

Se calcula un resumen para cada continente y año. Se muestra 2007, el último año disponible, para sumar poblaciones del mismo momento.

```r
continentes <- gapminder::gapminder %>%
  group_by(continent, year) %>%
  summarise(esperanza_vida = mean(lifeExp), renta = mean(gdpPercap),
            poblacion = sum(pop), .groups = 'drop') %>%
  arrange(desc(esperanza_vida))
continentes %>% filter(year == max(year))
```

```
# A tibble: 5 x 5
  continent  year esperanza_vida  renta  poblacion
  <fct>     <int>          <dbl>  <dbl>      <dbl>
```

```
1 Oceania    2007           80.7 29810.   24549947
2 Europe     2007           77.6 25054.  586098529
3 Americas   2007           73.6 11003.  898871184
4 Asia       2007           70.7 12473. 3811953827
5 Africa     2007           54.8  3089.  929539692
```

7. Formato largo y ancho

Se transformaron las columnas por nombre, posición y exclusión; las tres selecciones dan el mismo resultado. Después se recuperó el formato ancho.

```
set.seed(1)
ex_wide <- data.frame(id = paste0('gene', 1:4),
  annotation = paste(c('m', 'k', 'l', 'y'), 'protein'),
  L4_control_A1 = rnorm(4, 20, 3), C6_control_A1 = rnorm(4, 20, 3),
  L4_chemical_A1 = rnorm(4, 20, 3), C6_chemical_A1 = rnorm(4, 20, 3))
ex_tidy <- pivot_longer(ex_wide, L4_control_A1:C6_chemical_A1,
                        names_to = 'expression', values_to = 'sample',
                        cols_vary = 'slowest')
por_indice <- pivot_longer(ex_wide, 3:6, names_to = 'expression',
                           values_to = 'sample', cols_vary = 'slowest')
por_exclusion <- pivot_longer(ex_wide, -c(id, annotation),
                              names_to = 'expression', values_to = 'sample',
                              cols_vary = 'slowest')
identical(ex_tidy, por_indice)
```

```
[1] TRUE
```

```
identical(ex_tidy, por_exclusion)
```

```
[1] TRUE
```

```
ex_wide2 <- pivot_wider(ex_tidy, names_from = expression, values_from = sample)
ex_wide2
```

```
# A tibble: 4 x 6
  id    annotation L4_control_A1 C6_control_A1 L4_chemical_A1 C6_chemical_A1
  <chr> <chr>              <dbl>         <dbl>          <dbl>          <dbl>
1 gene1 m protein           18.1          21.0           21.7           18.1
2 gene2 k protein           20.6          17.5           19.1           13.4
3 gene3 l protein           17.5          21.5           24.5           23.4
4 gene4 y protein           24.8          22.2           21.2           19.9
```

Se separó el genotipo y se conservaron las cuatro columnas del ejemplo.

```
resultado <- ex_tidy %>%
  separate(expression, into = c('genotype', 'tratamiento', 'replica'),
           sep = '_') %>%
  select(id, annotation, genotype, expression = sample)
resultado
```

```
# A tibble: 16 x 4
   id    annotation genotype expression
   <chr> <chr>      <chr>         <dbl>
 1 gene1 m protein  L4             18.1
 2 gene2 k protein  L4             20.6
 3 gene3 l protein  L4             17.5
 4 gene4 y protein  L4             24.8
 5 gene1 m protein  C6             21.0
 6 gene2 k protein  C6             17.5
 7 gene3 l protein  C6             21.5
 8 gene4 y protein  C6             22.2
 9 gene1 m protein  L4             21.7
10 gene2 k protein  L4             19.1
11 gene3 l protein  L4             24.5
12 gene4 y protein  L4             21.2
13 gene1 m protein  C6             18.1
14 gene2 k protein  C6             13.4
15 gene3 l protein  C6             23.4
16 gene4 y protein  C6             19.9
```

8. Transformaciones con across

Se pasaron los factores a mayúsculas y se sustituyeron los valores menores que 3 por `NA` o por `CERO`, según el ejemplo.

```
head(iris %>% mutate(across(where(is.factor), toupper)))
```

```
  Sepal.Length Sepal.Width Petal.Length Petal.Width Species
1          5.1         3.5          1.4         0.2  SETOSA
2          4.9         3.0          1.4         0.2  SETOSA
3          4.7         3.2          1.3         0.2  SETOSA
4          4.6         3.1          1.5         0.2  SETOSA
5          5.0         3.6          1.4         0.2  SETOSA
6          5.4         3.9          1.7         0.4  SETOSA
```

```
head(iris %>% mutate(across(where(is.numeric), ~ ifelse(.x < 3, NA, .x))))
```

```
  Sepal.Length Sepal.Width Petal.Length Petal.Width Species
1          5.1         3.5           NA          NA  setosa
2          4.9         3.0           NA          NA  setosa
3          4.7         3.2           NA          NA  setosa
4          4.6         3.1           NA          NA  setosa
5          5.0         3.6           NA          NA  setosa
6          5.4         3.9           NA          NA  setosa
```

```
head(iris %>% mutate(across(where(is.numeric), ~ ifelse(.x < 3, 'CERO', .x))))
```

```
  Sepal.Length Sepal.Width Petal.Length Petal.Width Species
1          5.1         3.5         CERO        CERO  setosa
2          4.9           3         CERO        CERO  setosa
```

```
3          4.7         3.2         CERO        CERO  setosa
4          4.6         3.1         CERO        CERO  setosa
5          5.0         3.6         CERO        CERO  setosa
6          5.4         3.9         CERO        CERO  setosa
```

9. Tabla de estadísticos

Se calcularon el máximo, mínimo, mediana y media ± desviación típica para cada variable del ejemplo.

```
set.seed(1)
df <- tibble(x = runif(100), y = runif(100), z = runif(100))
tabla <- data.frame(Variable = names(df),
  Maximo = sapply(df, max), Minimo = sapply(df, min),
  Mediana = sapply(df, median),
  'Media ± SD' = paste0(round(sapply(df, mean), 2), ' ± ',
                        round(sapply(df, sd), 2)), check.names = FALSE)
knitr::kable(tabla, digits = 2, row.names = FALSE)
```

Variable	Maximo	Minimo	Mediana	Media ± SD
x	0.99	0.01	0.49	0.52 ± 0.27
y	0.99	0.01	0.52	0.52 ± 0.27
z	0.98	0.03	0.38	0.44 ± 0.28